DATA ENGINEERING MODULE 1

Verkennen, ontwerpen en visualiseren van de Contoso dataset.

Jarno van Bers
#2163262

25 oktober 2026

Samenvatting

In dit document wordt het proces van data-analyse tot dashboardrealisatie beschreven voor de salesdataset van het fictieve bedrijf Contoso. Het doel is om de beschikbare gegevens om te zetten naar bruikbare informatie voor een Global Sales Manager en een Product Portfolio Manager.

De datasets zijn met behulp van Python en Pandas geïmporteerd, geanalyseerd, opgeschoond en verrijkt. Hierbij is onder andere gekeken naar ontbrekende waarden, duplicaten, datatypes en de onderlinge samenhang tussen de tabellen. Een belangrijke bevinding was dat retouren niet consistent in de oorspronkelijke omzet- en kostenbedragen waren verwerkt. Hiervoor zijn aanvullende kolommen berekend die rekening houden met retouren. Daarnaast zijn gegevens over het GDP per inwoner van de World Bank toegevoegd om de samenhang tussen economische ontwikkelingen en de omzet van Contoso te verkennen. De opgeschoonde datasets zijn opgeslagen als afzonderlijke Parquet-bestanden.

Op basis van deze gegevens is een dimensioneel model opgesteld met Sales als centrale feitentabel en bijbehorende dimensies. Voor gebruik door de eindgebruiker zijn de gegevens voorzien van duidelijke benamingen in een semantisch model. Vervolgens zijn voor beide persona's in totaal tien user stories met een definition of done opgesteld. Deze vormen de basis voor de mock-ups en de uiteindelijke dashboards in Power BI. De analyses zijn daarnaast uitgewerkt in Python.

Uit het salesdashboard blijkt dat de omzet in 2013 ten opzichte van 2012 met 3,31% is afgenomen en het brutomargepercentage met circa 0,6 procentpunt is gedaald. Met name de categorie cameras and camcorders draagt bij aan de omzetdaling. Daartegenover staan groei binnen het online verkoopkanaal en de Aziatische markt. De vergelijking met GDP per inwoner laat zien dat een stijging hiervan niet in alle onderzochte markten samengaat met omzetgroei voor Contoso.

Het productportfolio dashboard biedt verdere inzichten in verschillen tussen productcategorieën, subcategorieën en producenten. Deze bevindingen geven aanleiding om teruglopende productgroepen nader te onderzoeken en mogelijkheden voor aanpassing van het assortiment en gesprekken met leveranciers te verkennen.

Het resultaat is een uitgewerkt proces van databewerking tot rapportage, waarmee beide persona's hun informatiebehoeften kunnen onderzoeken. In de reflectie wordt teruggekeken op de uitvoering, waarbij het bewaken van de scope en het bewust gebruiken van AI als ondersteuning belangrijke leerpunten vormen.

Inhoudsopgave

Samenvatting 1
Inhoudsopgave 2
1. Inleiding 3
2. Data-Analyse 4
2. 1 Feiten 4
2.2 Dimensies 6
3. Ontwerp datamodel 12
4. User stories 16
5. Mock-ups 20
Sales dashboard mockup 20
Product portfolio dashboard mockup 22
6. Bevindingen 24
7. Reflectie 33
8. Bronnen 35
9. Tabellenlijst 35
10. Figurenlijst 36
11. Bijlagen 37

1. Inleiding

In dit document zal het proces van data-analyse tot aan dashboard realisatie in PowerBI worden beschreven voor de salesdataset van het fictieve bedrijf Contoso.

In hoofdstuk 2 wordt aangevangen met een analyse van de beschikbare data. Er is hierbij voor gekozen om de datasets te analyseren, valideren en transformeren met behulp van Python en Jupyter in Visual Studio Code. Per beschikbaar gestelde dataset worden de stappen van importeren, analyseren, opschonen en valideren doorlopen. Er wordt ook een externe dataset toegevoegd, GDP per capita. Als voor alle datasets de stappen zijn doorlopen worden onderlinge relaties gecontroleerd en gevalideerd, waarna gegevens opgeslagen worden als bron voor verwerking in rapportages.

In hoofdstuk 3 wordt op basis van de bevindingen uit de initiële analyse een dimensioneel model in de vorm van een sterschema opgesteld. Daarnaast wordt een semantisch model gecreëerd voor de eindgebruiker.

Hoofdstuk 4 betreft het opstellen van userstories aan de hand van 2 persona's; de global salesmanager en de product portfolio manager. Eerst worden de rol en de informatiebehoefte van de persona's toegelicht. Vervolgens worden op basis van deze persona's userstories opgesteld met een bijbehorende definition of done.

In hoofdstuk 5 worden de userstories gevisualiseerd door middel van mock ups gemaakt met behulp van mokkup.ai. De verschillende visualisaties worden per userstory toegelicht.

Op basis van de mockups worden de dashboards in PowerBI uitgewerkt. Vanuit het perspectief van de persona's worden in hoofdstuk 6 de gebruikswijze en bevindingen van het uitgewerkte dashboard vastgelegd.

In hoofdstuk 7 volgt een reflectie op het proces van het tot stand komen van het dashboard.

2. Data-Analyse

Voordat data in gebruik genomen wordt dient er eerst een analyse uitgevoerd van de beschikbare data. Ten eerste is dit belangrijk om een eerste indruk te krijgen van de aanwezige data, hierbij is aandacht besteed aan:

- Waar gaat de data over?
- Wat is de context van de data?
- Wat zijn de feiten en wat zijn de dimensies?

Zo kan later bij het modelleren van het datamodel een duidelijk sterschema gemaakt worden met bijbehorende userstories die aansluiten op de gegevens die de dataset aanlevert.

Ten tweede dient er aandacht besteed te worden aan de kwaliteit van de data. Datakwaliteit is belangrijk voor het creëren van bruikbare databases die correcte output leveren (ter Braake, 2022). Voor alle individuele datasets zijn de volgende stappen doorlopen:

1. Importeren van het .CSV-bestand als een Pandas Dataframe
2. Initiële analyse die kijkt naar de kolommen, datatypes, duplicaten, unieke waarden en lege waarden in de dataset.
3. Diepere analyse op verbanden en afwijkingen en het eventueel opschonen en verrijken hiervan.
4. Data validatie gebaseerd op algemene controles en bevindingen voortkomend uit de data-analyse.

Deze stappen zijn gebaseerd op de methode gehanteerd in het boek Python for Data Analysis (McKinney, 2022). Hoewel Pandas in de jaren sinds publicatie verder is doorontwikkeld, zijn de stappen nog steeds relevant voor een correcte data-analyse.

Als alle datasets zijn geanalyseerd vindt er validatie plaats op onderlinge samenhang. Waarna export van de data plaatsvindt om in gebruik te nemen voor het dashboard.

Voor een volledige analyse van de datasets wordt gerefereerd naar het notebook zelf. Onderstaand worden de belangrijkste bevindingen per dataset toegelicht.

2. 1 Feiten

Sales

Import

Bij het importeren van de sales dataset werden een aantal waarden initieel als tekst ingeladen, terwijl dit decimalen betrof. Door het aanpassen van de import parameters is dit probleem opgelost.

Initiële analyse

Een initiële analyse laat zien dat de salesdataset 2.282.482 records bevat met unieke keys en geen lege waarden. De grain van de data is dat één regel gelijk is aan één verkooprecord. Hiervan zijn gegevens beschikbaar omtrent de kosten per stuk, omzet per stuk, kortingspercentage, retouren en totale kosten en omzet per order.

Naast deze gegevens zijn er keys aanwezig voor de channel, stores, product en promotion dimensies. Via deze keys kunnen later relaties gelegd worden met de dimensies.

Initieel liep de relatie met geography via de store dimensie, deze is door middel van mapping direct gelinkt aan de feitentabel om een zuiver sterschema te krijgen met zo min mogelijk subdimensies.

Daarnaast is er een nieuwe DateKey toegevoegd die met de calendar koppelt op basis van een integer. Deze vorm van een surrogate key wordt over het algemeen gezien als best practice. (Kimball Group, 2026).

Diepere analyse en opschonen
Uiteindelijk is er gekeken naar de presentatie van de totale omzet en kosten in de dataset. De eerste analyse liet zien dat er in de presentatie van de totale omzet geen rekening gehouden leek te worden met retouren bij de totale omzet, waar dit in de kosten wel het geval was. Om deze hypothese te controleren is een nieuwe kolom toegevoegd die rekening houdt met de retouren in de totale omzet. De berekening is als volgt:

SalesAmountRet

=

(Verkoophoeveelheid * verkoopprijs) – (retouren * verkoopprijs) – (korting)

Deze is vervolgens vergeleken met de waarde in de originele SalesAmount kolom. De afwijking hiervan was hier telkens het aantal retouren maal de verkoopprijs. Voor een zuiver beeld van de omzet minus retouren is dit dus een betere waarde.

Voor de totale inkoopkosten werd aanvankelijk aangenomen dat de retouren hier wel correct verwerkt waren in de totale kostprijs. Een verdere analyse liet zien dat verwerking van de retouren niet consistent in de totale kosten verwerkt wordt door de dataset heen. Hiervoor is een nieuwe kolom toegevoegd voor de totale kosten waarbij rekening gehouden wordt met retouren. De berekening is als volgt:

TotalCostRet

=

(Verkoophoeveelheid * inkoopprijs) – (retouren * inkoopprijs)

Deze waarden zijn vervolgens vergeleken met de TotalCost kolom. Hieruit bleek dat het verwerken van retouren in de TotalCost inconsistent was. Voor een zuivere vergelijking van totale kosten en berekeningen van de brutomarge wordt daarom de nieuwe kolom aangehouden.

Deze toevoegingen zorgen ervoor dat er zuivere analyses op kosten en omzet gemaakt kunnen worden na verwerking van retouren. De originele waarden zijn binnen de dataset behouden, omdat deze wel inzicht kunnen verlenen in de verwerking van retouren.

Validatie
Na de analyse en het opschonen van de dataset vindt validatie van de dataset plaats. Validatieregels betreffen controles op een unieke primary key en ontbrekende waarden in de primary key.

Daarnaast zijn er logische controles, zoals het feit dat retouren niet het aantal verkopen kan overschrijden. De logica achter de nieuwe toegevoegde waarde wordt getoetst aan de bovenstaande verbanden.

2.2 Dimensies

Voor de dimensies volgen we dezelfde aanpak als omschreven in de inleiding. Vanwege weinig afwijkingen in de import procedure wordt deze voor de dimensies niet expliciet toegelicht.

Product data

Initiële analyse

De initiële analyse laat zien dat er 1690 unieke ProductKeys in de productdataset zitten. Dit sluit aan op de 1689 unieke productkeys in de sales dataset. Het enige product dat niet voorkomt in de salesdata is de "*A. Datum Compact Digital Camera M200 Black*".

Bij de initiële import worden de UnitCost en UnitPrice niet omgezet naar floats. Dit komt doordat er standaard een dollarteken in de waarden binnen de kolom verwerkt zit, waardoor deze als string wordt geïnterpreteerd. Om dit op te lossen is het dollarteken verwijderd en zijn de komma's omgezet naar punten, vervolgens zijn de waarden omgezet naar floats.

Vervolgens is gecontroleerd of er afwijkingen zijn tussen de kostprijs of verkoopprijs in de product data en de sales data. In beide gevallen is er geen sprake van afwijkingen. Omdat UnitCost en UnitPrice op transactieniveau in de salesdata zijn opgenomen, wordt aangenomen dat deze waarden de kostprijs en verkoopprijs vertegenwoordigen die op het moment van verkoop van toepassing waren. Gedurende de periode waarop de sales data betrekking heeft zijn deze ongewijzigd, gezien de aansluiting onderling.

Bestaande tekstwaarden zoals BrandName, Classname, etc. zijn onderzocht op duplicaten ontstaan door alternatieve schrijfwijzen. Uit deze analyse blijkt dat nagenoeg iedere waarde in de ProductName kolom naast de naam ook de kleur van het product bevat.

Diepere analyse en opschonen

Bij de diepere analyse van de product dataset is de eerdere constatering onderzocht dat iedere ProductName een kleur bevat. Uiteindelijk leidde dit tot de conclusie dat bij slechts 1 product de kleur niet is vermeld.

De volgende stap was om de kleur in een aparte kolom op te nemen, zodat deze later als aparte product eigenschap gebruikt kan worden om de records in de sales data mee te analyseren. Door middel van het splitten van de ProductName en vervolgens slicen werd het laatste woord van de ProductName opgeslagen in de kolom ProductColor. Voor een overheersend deel van de waarden leidde dit tot een correcte opslag van de ProductColor.

Voor het product zonder kleur op het einde van de naam is deze waarde handmatig omgezet naar de waarde "*No Color*". Ten tweede waren er twee schrijfwijzen voor "*blue*" aanwezig, door middel van de title functie zijn deze gecorrigeerd. Uiteindelijk was er geen rekening gehouden met kleuren die bestaan uit twee woorden, in de data set komt de kleur Silver Grey voor. Deze zijn vervolgens met een loc functie toegevoegd aan de ProductColor kolom.

Met behulp van de ProductColor kolom is vervolgens een nieuwe kolom toegevoegd "ProductNameNoColor" waar de productnaam naam wordt opgeslagen zonder kleur met behulp van regex. De splitsing van de kleur maakt het mogelijk product verkopen te analyseren onafhankelijk van kleur en vervolgens dieper in te zoomen op kleurvoorkeuren voor het betreffende product.

De ProductNameNoColor maakt het ook mogelijk de verschillende omschrijvingen te controleren op duplicaten. Hierbij wordt geconstateerd dat zelfs bij de productnamen zonder kleuren verschillende producten dezelfde omschrijving hebben met een andere productnaam.

Validatie
Zoals bij de voorgaande dataset wordt er gecontroleerd op unieke of ontbrekende primary keys. Daarnaast worden de waarden in de "*ProductNameNoColor*" kolom gevalideerd op correcte eliminatie van kleuren.

Calendar data

Initiële analyse
De initiële analyse laat zien dat de calendar dataset 14 jaren bevat, waarvan alle waarden een integer of string zijn. In de set wordt geen specifieke DateKey benoemd, maar wel een DateInt. Deze matcht niet direct met de DateKey in de sales data, zoals eerder beschreven is om deze reden een integer toegevoegd aan de salesdataset.

Diepere analyse en opschonen
De diepere analyse leidt tot de conclusie dat er twee year en twee day kolommen aanwezig zijn. Er is besloten van beide waarden één kolom te laten vallen vanwege onnodige redundantie

Met behulp van de pandas datetime functie is de kolom Date toegevoegd als aparte kolom die als datumwaarde fungeert. Er is een aparte DateKey kolom toegevoegd die gebruikt kan worden als primary key voor de calendar en foreignkey in de sales dataset. Deze DateKey is een integer datumsleutel in de vorm van YYYYMMDD. Uiteindelijk is er voor gekozen waarden voor 2011 en na 2013 te laten vallen uit de dataset om zo performance te verbeteren voor analyse van sales data.

Validatie
Zoals bij de voorgaande dataset wordt er gecontroleerd op unieke of ontbrekende primary keys. Daarnaast wordt er expliciet gecontroleerd of de nieuwe Date kolom correct is omgezet naar een datetime datatype.

Geography data

Initiële analyse
De initiële analyse laat zien dat er in totaal 674 GeographyKeys zijn. Hier zitten zowel continenten, landen als provincies in. Hoewel er in de GeographyType 4 unieke waarden voorkomen lijken er in de data geen aanvullende data aanwezig te zijn die de attributen "State/Province" en "City" verder toelichten. Daarom zullen analyses beperkt blijven tot analyses op continent en land niveau. 3 van de RegionCountryName rijen bevatten geen waarden, deze hebben betrekking op de continenten en lijken redundant, gezien deze al benoemd worden in de ContinentName kolom.

Diepere analyse en opschonen
Er is voor gekozen de rijen met lege waarden voor de contintenten te laten vallen, gezien deze waarden ook met behulp van de ContinentName kolom gefilterd kunnen worden.

Validatie
Voor validatie wordt er gekeken naar ontbrekende of dubbele primary keys en ontbrekende waarden in de kolommen RegionCountryName en ContinentName.

Store data

Initiële analyse

De initiële analyse laat zien dat er 306 unieke StoreKeys zijn. Daarnaast valt erop dat er 305 gevulde waarden zijn voor EmployeeCount, voor 1 winkel is er dus geen werknemersaantal geregistreerd. Bij CloseReason zijn er maar 12 gevulde waarden en 294 lege waarden. Het uitgangspunt is dat deze waarden pas ingevuld worden bij het daadwerkelijk sluiten van een winkel.

Diepere analyse en opschonen

De GeographyKey is aanvankelijk verwerkt in deze dataset. Er is voor gekozen deze ook aan de sales dataset toe te voegen, zodat deze gegevens direct aan de feitentabel gekoppeld kunnen worden. Dit ligt in lijn met de theorie van het sterschema, waarbij er één feitentabel is, sales, en meerdere dimensies die iets zeggen over deze feiten, in dit geval stores en geography (ter Braake, 2022).

Het toevoegen van de GeographyKey aan de salesdata is gedaan door middel van het mappen van de GeographyKey op basis van de reeds aanwezige StoreKey in de salesdata. De GeographyKey is hierbij nog wel in de originele store dataset aanwezig.

De kolom CloseReason bevat pas een waarde als deze van kracht is. Uit de analyse blijkt dat dit de waarden "*Relocation*" of "*Store*" kunnen zijn. Voor de waarde "*Store"* is het onduidelijk wat deze betreft. Het zou eventueel van toegevoegde waarde kunnen zijn om een Slowly Changing Dimension toe te voegen aan deze dataset die bijhoudt wanneer winkels zijn geopend en gesloten en eventueel verhuisd. Zo kan er bijvoorbeeld geanalyseerd worden hoe de omzetontwikkeling is na een verhuizing.

Er is getracht te achterhalen wat de reden is van de missende waarde bij EmployeeCount, echter geeft puur de dataset hier geen antwoord op om deze uit te sluiten of aan te passen.

De GeographyKeys in de store dataset hebben enkel betrekking op locaties met GeographyType "*City*", er is echter geen data aanwezig op welke stad dit betrekking heeft.

Validatie

Voor validatie wordt er gekeken naar ontbrekende of dubbele primary keys en tegenstrijdige statussen in de CloseReason en Status kolommen.

Promotions data

Initiële analyse

De initiële analyse laat zien dat er 28 unieke PromotionKeys zijn. Daarnaast zijn er meerdere waarden voor jaren, kwartalen, maanden en dagen aanwezig in de dataset. Eén van deze reeksen lijkt betrekking op de begindatum van de promotie en een andere op de einddatum. Uiteindelijk is er 1 PromotionKey voor verkopen zonder korting. PromotionKey en PromotionLabel lijken daarnaast dezelfde waarden te bevatten.

Diepere analyse en opschonen

In de analyse is voornamelijk aandacht besteed aan het uitvinden van het verband tussen promoties, kortingspercentages en de salesdataset. Hierbij is eerst één promotieactie geanalyseerd om een hypothese te creëren voor hoe de DiscountAmount op basis van de promotie en salesdata tot stand komt. Dit blijkt niet om percentages over de gehele order te gaan maar een percentage van de DiscountQuantity waarde en de UnitPrice. De formule voor DiscountAmount luidt als volgt:

DiscountAmount

=

Verkoopprijs * Kortingshoeveelheid * Kortingspercentage

Er is onderzocht of er een verband bestaat tussen de verkoophoeveelheid en het toepassen van korting binnen promoties. Op basis van de beschikbare data is geen eenduidige regel gevonden voor het aantal producten waarop korting wordt toegepast. Ook kon niet worden vastgesteld of korting pas wordt verleend vanaf een bepaalde afnamehoeveelheid of een bepaald aankoopbedrag.

De begin- en einddatum zijn omgezet naar duidelijke kolommen, waarbij de originele kolommen ook voorzien zijn van de voorzetsels "*End*" en "*Start*" om duidelijke te signaleren waar deze betrekking op hebben.

Uiteindelijk was de promotie "*European Back-to-School Promotion*" niet correct benoemd, dit is aangepast.

Validatie
De validatie vindt plaats op ontbrekende of dubbele waarden in de set. Daarnaast wordt er gekeken naar de datums en correcte kortingspercentages.

Product category en productsubcategory data

Initiële analyse
Aanvankelijk is er gekeken naar beide datasets individueel. Echter blijkt dat ProductCategory maar 1 waarden bevat buiten de key die deze verbindt met de productdataset. Om deze reden is ervoor gekozen deze sets samen te voegen tot 1 set die een subdimensie vormt van de Product, gekoppeld via de ProductSubCategoryKey.

Diepere analyse en opschonen
Diepere analyse laat zien dat de sales data niet betrekking heeft op alle producten in het assortiment van Contoso, *Games and Toys* en *Home Appliances* vallen niet binnen de dataset.

Validatie
Validatie vindt plaats op aanwezigheid van unieke en ontbrekende primary keys, zowel met de product data als onderling tussen productcategory en productsubcategory.

Channel data

De channel dataset bevat weinig gegevens. Er zijn 4 verkoopkanalen; store, online, catalog en reseller. Om deze te koppelen aan de salesdataset is de Channel kolom hernoemd naar ChannelKey conform de sales dataset.

Gross Domestic Product (GDP)

Als externe dimensie zijn gegevens over het GDP per inwoner per land per jaar in dollars toegevoegd op basis van een dataset van de World Bank Group. (World Bank Group, 2026) Deze zijn vervolgens geïmporteerd en verder opgeschoond. De dataset dient om te onderzoeken of stijgingen en dalingen in het GDP per inwoner samengaan met veranderingen in de omzet van Contoso in dit land.

Initiële analyse
De dataset bevat gegevens van 265 landen en groeperingen van landen met kolommen voor ieder jaar vanaf 1960 tot en met heden. Kolommen kunnen ook lege waarden bevatten als destijds geen gegevens geregistreerd zijn.

Diepere analyse en opschonen
Om de dataset bruikbaar te maken in combinatie met de aanwezige sales data en geografische gegevens is er een nieuwe dataframe gecreëerd waar enkel gegevens in aanwezig zijn met betrekking tot de relevante jaren. Vervolgens is deze dataframe smaller gemaakt door de jaren verticaal te presenteren in één kolom in plaats van een kolom voor ieder jaar apart.

Vervolgens is gecontroleerd welke landen uit de geography dataset ook in de GDP-dataset aanwezig waren. 7 landen konden initieel niet herkend worden. Door middel van zoeken op delen van de landnamen, zijn uiteindelijk 6 van de 7 landen gevonden in de dataset. Voor Taiwan ontbreken er gegevens over het GDP per inwoner in de dataset.

Met behulp van mapping zijn de landnamen in de GDP-dataset toegevoegd als key aan de dataset.

Validatie

Er vindt validatie plaats op dubbele waarden van combinaties van land en jaar en ontbrekende Keys.

Integrale validatie

Na afronding van alle individuele analyses wordt één laatste integrale validatie uitgevoerd. Deze bestaat uit controles op keys die zich in zowel de feitentabel als de dimensietabellen dienen te bevinden om zuivere analyses op met behulp van de dimensies uit te voeren. Deze validaties zijn niet uitputtend en enkel bedoeld om voor de huidige sets aannames te controleren.

Dataprofiel

Tabel 1 Dataprofiel van de opgeschoonde data.

Tabel	Rijen	Kolommen	Primaire sleutel	Uniek	Lege waarden	Opmerking
Sales	2.282.482	21	SalesKey	Ja	0	Grain: één verkoopregel
Product	1.690	11	ProductKey	Ja	0	1 product komt niet in Sales voor
Calendar	1.096	10	DateKey	Ja	0	2011–2013
Geography	671	4	GeographyKey	Ja	0	3 continentrijen verwijderd
Stores	306	8	StoreKey	Ja	1	12 CloseReason-waarden
Promotions	28	16	PromotionKey	Ja	0	1 promotie zonder korting
Productcategory	44	4	ProductSubcategoryKey	Ja	0	Category + subcategory samengevoegd
Channel	4	2	ChannelKey	Ja	0	Store, online, catalog, reseller
GDP	795	5	(CountryKey, Year)	Ja	0	265 landen; Taiwan ontbreekt

Tabel 1 vat de omvang en kwaliteit van de opgeschoonde datasets samen. De aantallen zijn geteld op de parquet-bestanden die als bron voor beide rapportages dienen.

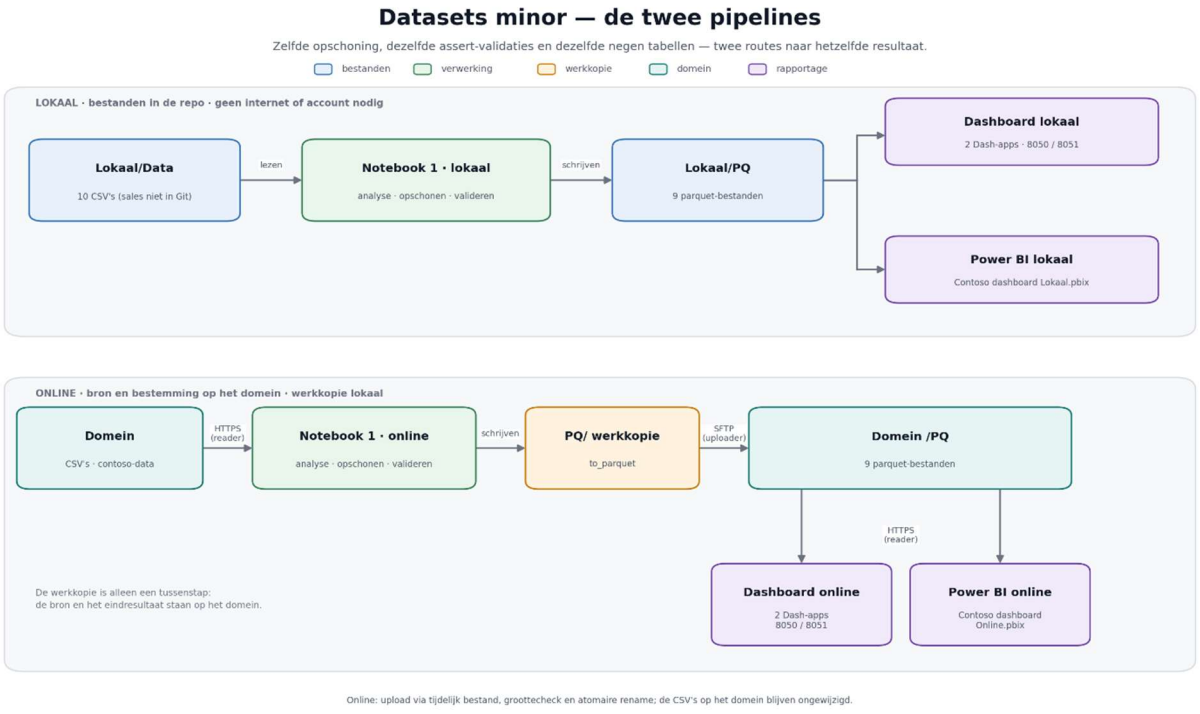
De sales-tabel is met 2,28 miljoen rijen de grootste; de andere tabellen zijn klein genoeg om als dimensie te gebruiken. De GDP-tabel bevat 265 landen en groeperingen; alleen de 33 Contoso-landen zijn voor de analyse relevant.

Opslag

Uiteindelijk worden de opgeschoonde datasets opgeslagen als afzonderlijke Parquet-bestanden. Parquet maakt gebruik van kolom gebaseerde opslag en efficiënte compressie, waardoor bestanden doorgaans kleiner zijn en sneller kunnen worden ingelezen dan bijvoorbeeld CSV-bestanden. Dit resulteert in kortere querytijden, efficiënter geheugengebruik en een lagere benodigde opslagcapaciteit (Databricks, 2026).

De oplossing bestaat uit drie lagen. De eerste laag is de brondata: de Contoso-CSV's en de World Bank-GDP-dataset. De tweede laag is de gegevensopslag: de opgeschoonde en gevalideerde parquet-bestanden. De derde laag is de rapportage: het Power BI semantische model en de Python/Dash-dashboards. Beide rapportages lezen dezelfde parquet-bestanden, waardoor de cijfers aansluiten. Figuur 1 laat de stroom zien.

De pipeline is reproduceerbaar met de notebooks en environment.yml; de README in de Datasets-map beschrijft de runvolgorde.



Figuur 1 Architectuur en gegevensstroom: brondata, parquet als opslag laag en twee rapportagelagen.

3. Ontwerp datamodel

Op basis van de beschikbare data en de verkenning hiervan zal een concept van een dimensioneel model gemaakt worden. Dit wordt gedaan op basis van het sterschema, een schema waarbij er 1 feitentabel is en meerdere dimensietabellen die aanvullende informatie geven over deze feitentabel (ter Braake, 2022).

Dimensioneel model

Dit model is terug te zien in Figuur 2 Dimensioneel model. Omwille van de leesbaarheid zijn niet alle gegevens in de tabellen verwerkt. In Bijlage A is het dimensioneel model terug te zien na import in PowerBI. Door de toevoeging van de ProductCategory tabel en GDP-tabel, kan er van een Snowflake schema gesproken worden, gezien er kleine sub dimensies ontstaan die iets zeggen over een andere dimensie.

Voor alle dimensies behalve de GDP is sprake van een één op veel relatie. De Product_Category tabel is een subdimensie van product.

GDP betreft een aparte relatie met de Geography dimensie en de Calendar dimensie. Via de CountryKey koppelt GDP aan de CountryName in de Geography Dimensie, wat een veel-op-veel relatie is. De GDP-tabel koppelt met de Calendar tabel door middel van de Year kolom.

Voor beide relaties is een enkelvoudige filterrichting ingesteld vanuit Geography en Calendar naar GDP. Hierdoor beperkt een landselectie de GDP-gegevens tot het betreffende land en een jaarselectie tot het betreffende jaar. GDP filtert daarbij niet terug naar Geography of Calendar.

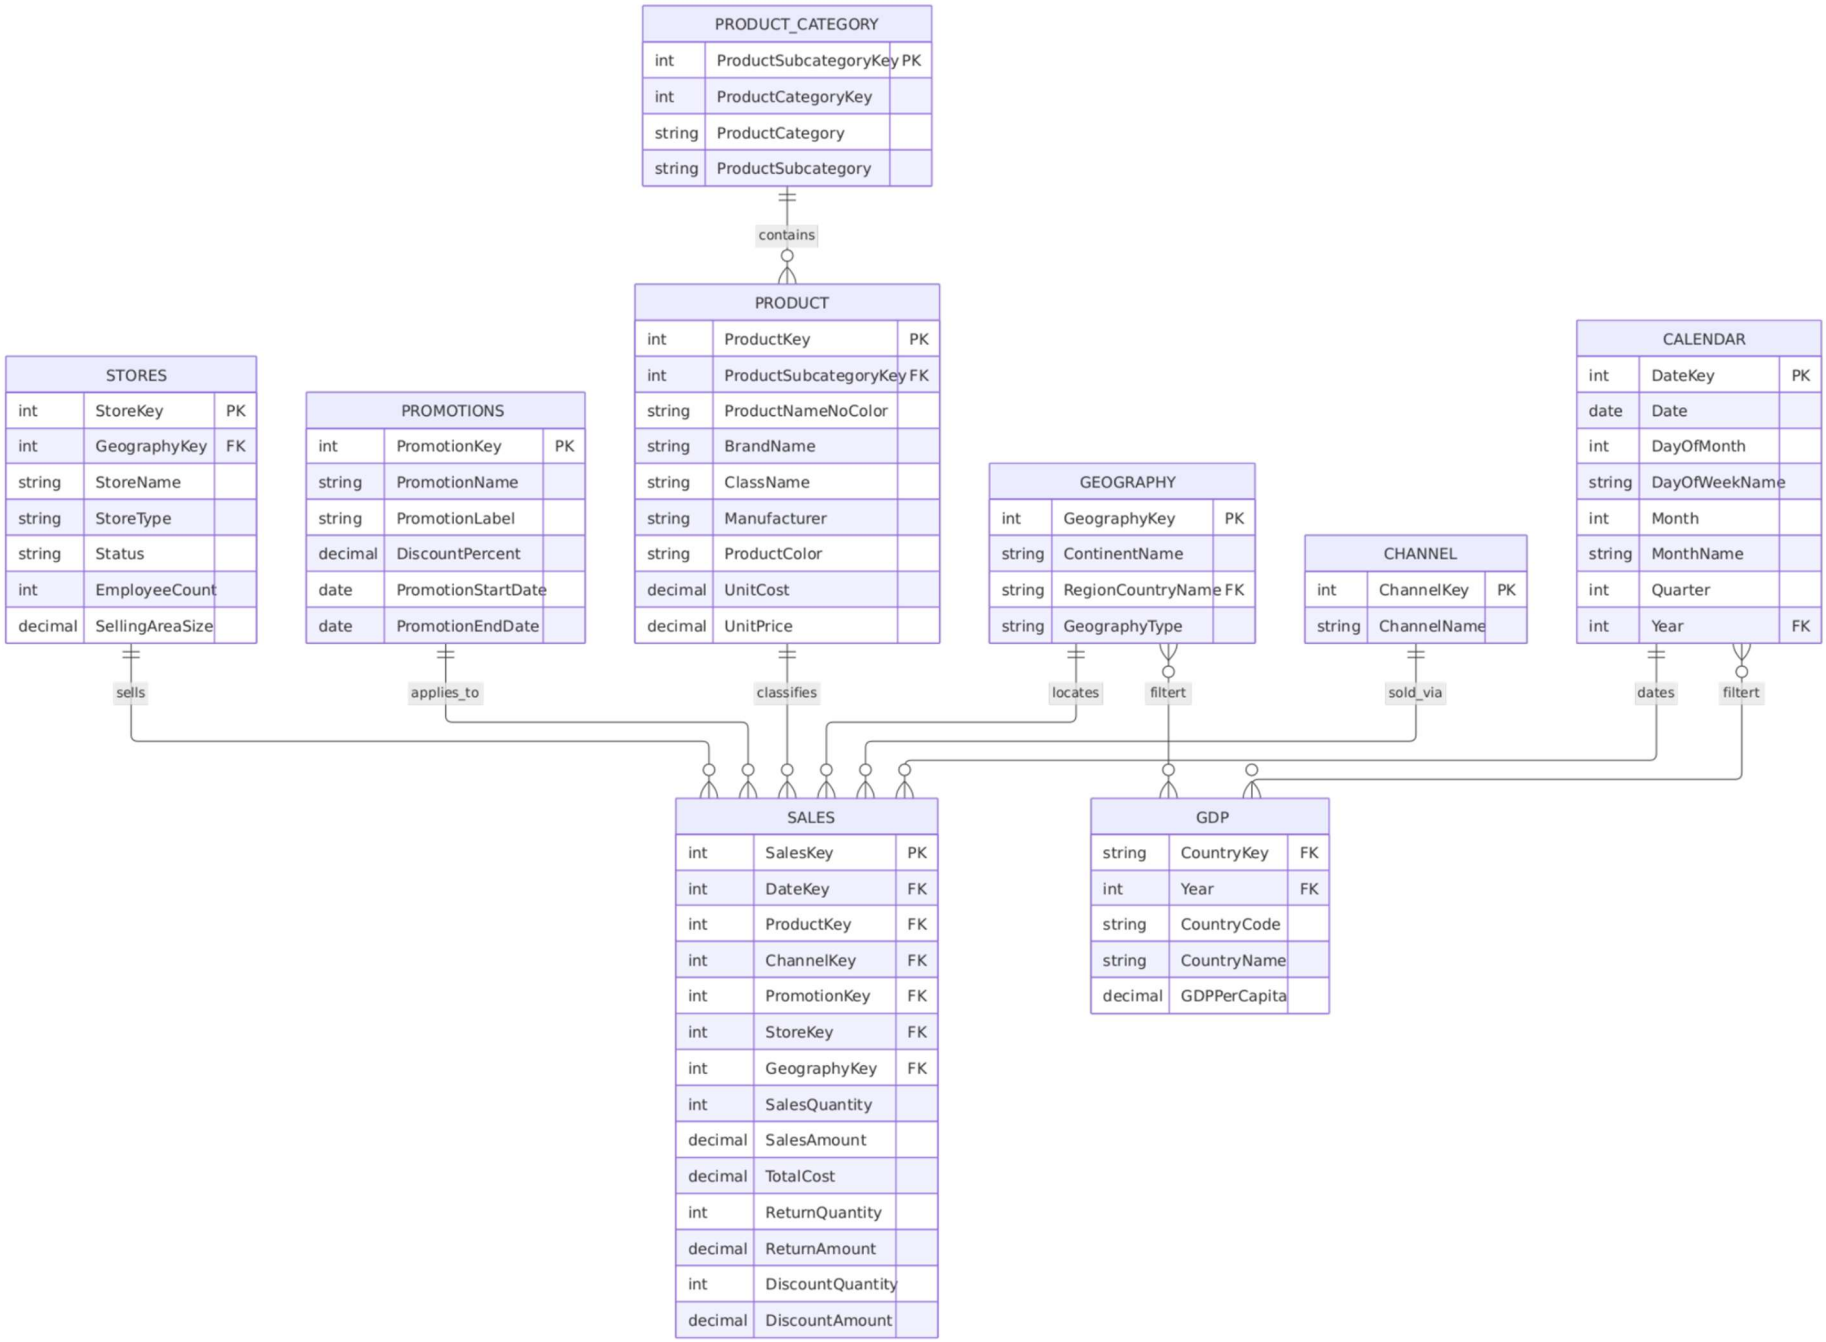
In Tabel 2 Dimensieverantwoording van de Contoso salesdata met de verschillende dimensies.zijn de relaties tussen de salesdata en de verschillende dimensies toegelicht.

Dimensie	Grain	Sleutel	Rijen	Relatie	Bron
Product	1 rij per product	ProductKey	1.690	1:* naar Sales	Product.csv
Productcategory	1 rij per subcategorie	ProductSubcategoryKey	44	1:* naar Product	ProductCategory + ProductSubcategory
Calendar	1 rij per dag	DateKey	1.096	1:* naar Sales	Calendar.csv
Geography	1 rij per geografie	GeographyKey	671	1:* naar Sales	Geography.csv
Stores	1 rij per winkel	StoreKey	306	1:* naar Sales	Stores.csv
Promotions	1 rij per promotie	PromotionKey	28	1:* naar Sales	Promotions.csv
Channel	1 rij per kanaal	ChannelKey	4	1:* naar Sales	Channel.csv
GDP	1 rij per land-jaar	(CountryKey, Year)	795	M:M	World Bank

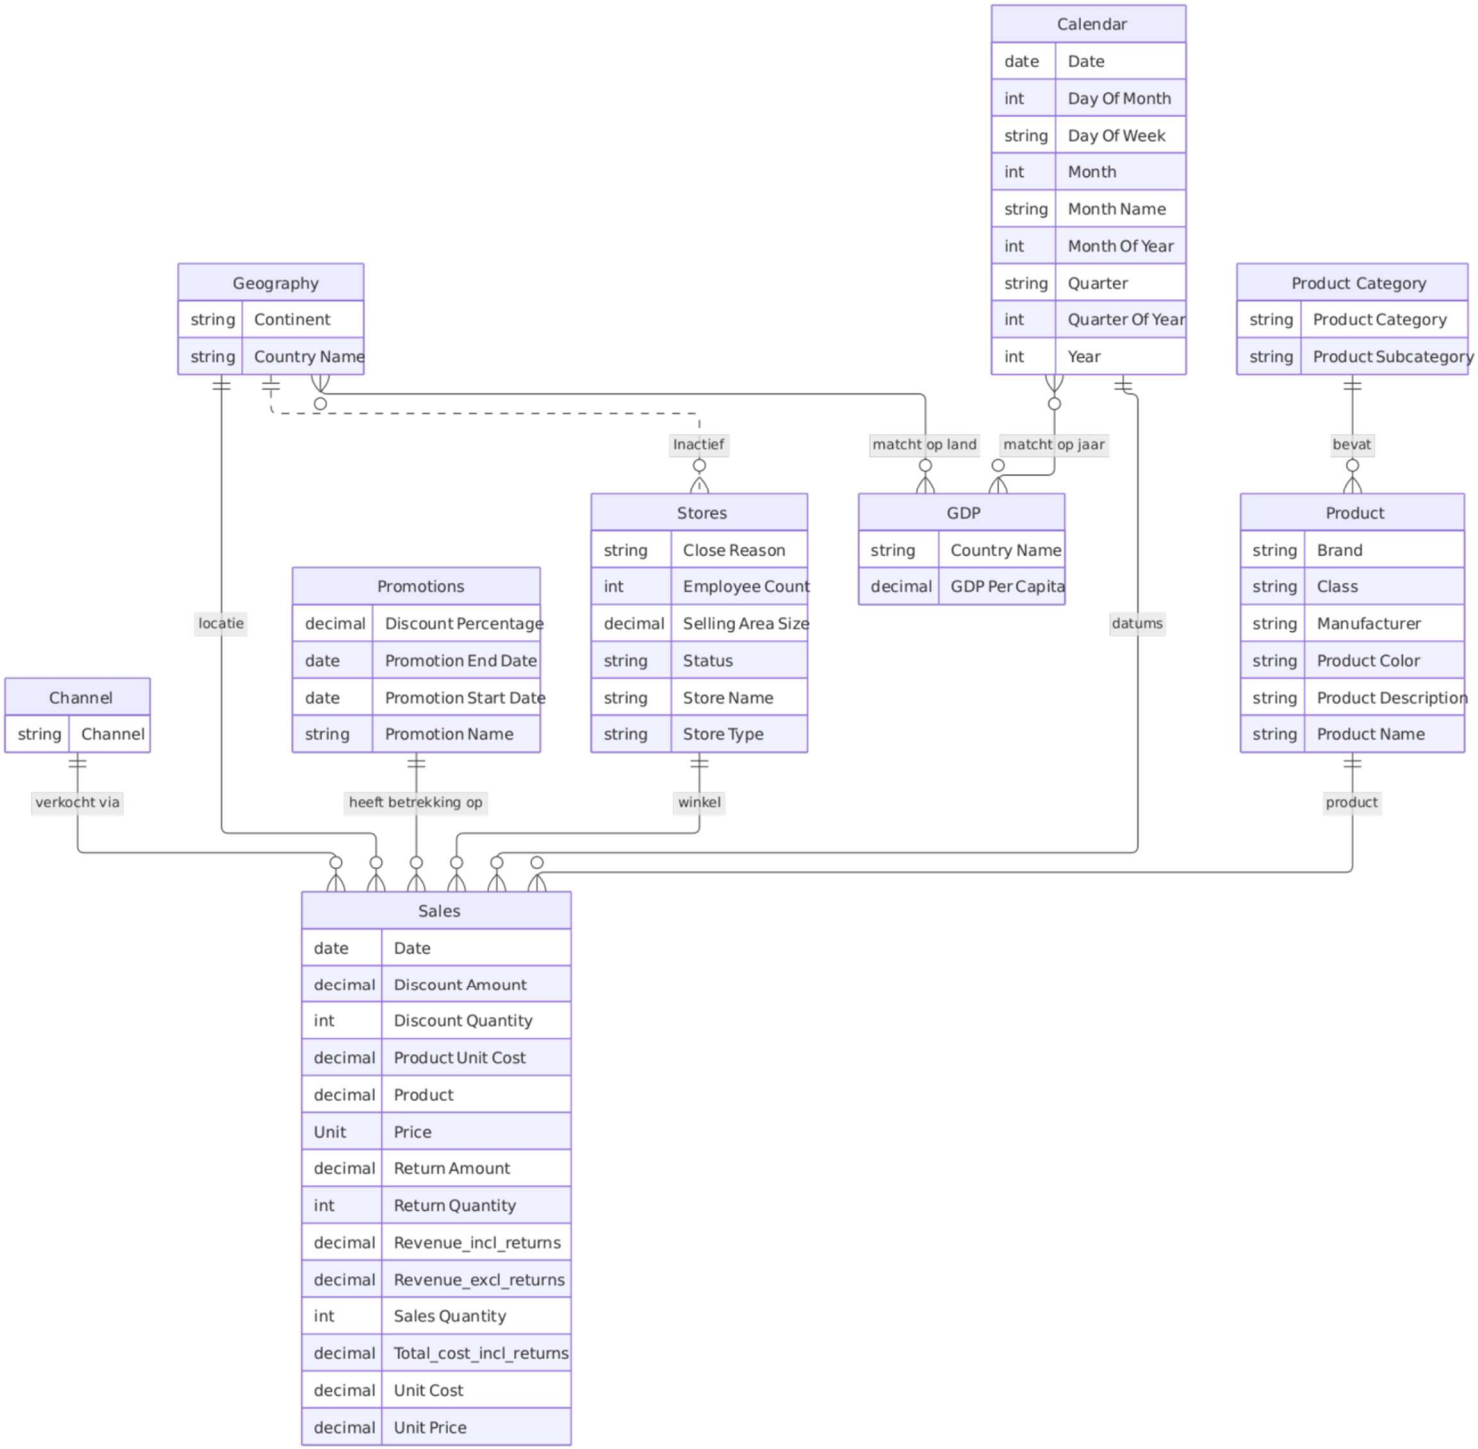
Tabel 2 Dimensieverantwoording van de Contoso salesdata met de verschillende dimensies.

Semantisch model

In Figuur 3 Semantisch model is een semantisch model toegevoegd dat gelijk is aan de gegevens waarmee gebruikers de data kunnen verkennen binnen PowerBI. Hierbij hebben gegevens een duidelijke benaming gekregen die geen gebruik maken van camelcase. Keys en andere technische gegevens zijn verborgen, zodat deze niet tot ruis leiden bij het gebruik van het dashboard. Het doel is hiervan om het dashboard toegankelijk te maken voor verkenning voor de eindgebruiker met eenduidige benamingen die niet open zijn voor interpretatie.



Figuur 2 Dimensioneel model



Figuur 3 Semantisch model

4. User stories

Alvorens invulling te geven aan het dashboard worden eerst 10 user stories gecreëerd aan de hand van een tweetal persona's. Gezien de focus ligt op data engineering zijn de omschrijvingen van de persona's vrij algemeen gehouden.

Persona's

Persona 1 — Global Sales Manager (GSM)
De Global Sales Manager is verantwoordelijk voor de algemene commerciële prestaties van Contoso over verschillende continenten en verkoopkanalen. De focus ligt niet op individuele producten, maar op het totale verkoopresultaat en de ontwikkeling daarvan.

Deze persona wil vooral weten of de organisatie haar commerciële prestaties verbetert, waar omzet en marge worden gerealiseerd en welke markten of verkoopkanalen achterblijven. Daarom zijn brutomarge en brutomargepercentage belangrijke stuurvariabelen. De belangrijkste informatiebehoeften zijn:

- Totale omzet, kosten, brutomarge en brutomargepercentage;
- Ontwikkeling van deze KPI's door de tijd;
- Verschillen tussen landen en continenten;
- Prestaties per verkoopkanaal;
- Vergelijking met eerdere perioden;
- Relatie tussen verkoopprestaties en externe economische factoren, zoals GDP per capita.

Door het hoge aggregatieniveau van deze informatiebehoeften wordt het dashboard niet dagelijks geraadpleegd. Immers zegt een wijziging in omzet of kosten van dag tot dag niet zoveel op dit gebied. De verwachting is eerder dat dit dashboard iedere 2 tot 4 weken geraadpleegd zal worden door de manager met weinig aanvullende vragen. Om deze reden valt deze persona het beste te typeren als een farmer. (ter Braake, 2022)

Persona 2 — Product Portfolio Manager (PPM)
De Product Portfolio Manager is verantwoordelijk voor de prestaties en samenstelling van het productportfolio. Waar de Global Sales Manager vooral kijkt naar het resultaat van markten en verkoopkanalen, richt deze persona zich op de vraag welke producten en productgroepen bijdragen aan dat resultaat.

De Product Portfolio Manager wil inzicht krijgen in welke productcategorieën, subcategorieën en individuele producten goed of juist minder goed presteren. Daarbij moet niet alleen naar omzet worden gekeken. Een product kan bijvoorbeeld veel verkocht worden, maar relatief weinig marge opleveren. Andersom kan een product met een lager verkoopvolume juist een hoge brutomarge genereren. De verwachting is dat dit dashboard wekelijks geraadpleegd zal worden door de product portfolio manager om de voortgang van uitgezette acties te controleren. Daarnaast kunnen er aanvullende informatiebehoeften ontstaan aan de hand van de inzichten die de manager graag verder wild onderzoeken binnen de context. Om deze reden kan deze gebruiker het best gedefinieerd worden als een farmer.

De belangrijkste informatiebehoeften zijn:

- Omzet en verkochte aantallen per productcategorie;
- Brutomarge en brutomargepercentage per product;
- Best en slechtst presterende producten;
- Ontwikkeling van productverkopen door de tijd;
- Verhouding tussen verkoopvolume en marge;
- Invloed van promoties op omzet, volume en brutomarge.

Userstories

ID	User story	Definition of Done
GSM-01	Als Global Sales Manager wil ik inzicht hebben in de totale omzet, kosten, brutomarge en brutomargepercentage, zodat ik de algemene verkoopprestaties kan beoordelen ten opzichte van voorgaand jaar.	Het dashboard toont KPI's voor omzet, kosten, brutomarge en brutomarge %. De waarden reageren correct op filters.
GSM-02	Als Global Sales Manager wil ik de ontwikkeling van omzet, kosten en brutomarge over de tijd kunnen analyseren, zodat ik trends en afwijkingen tussen perioden kan herkennen.	Omzet, kosten en brutomarge kunnen per maand en jaar worden weergegeven en tussen perioden worden vergeleken.
GSM-03	Als Global Sales Manager wil ik de omzet en brutomarge per land kunnen vergelijken met het GDP per capita, zodat ik kan analyseren of verkoopprestaties samenhangen met economische ontwikkelingen in een land.	Per land zijn omzet, brutomarge en GDP per capita beschikbaar en onderling vergelijkbaar in één visualisatie.
GSM-04	Als Global Sales Manager wil ik de verkoopprestaties per verkoopkanaal kunnen vergelijken, zodat ik kan beoordelen via welke kanalen de meeste omzet en brutomarge worden gerealiseerd.	Omzet en brutomarge kunnen per verkoopkanaal worden weergegeven en kanalen kunnen onderling worden vergeleken.
GSM-05	Als Global Sales Manager wil ik het aandeel van iedere productcategorie in de totale omzet kunnen inzien, zodat ik kan beoordelen welke productcategorieën het meest aan de omzet bijdragen.	Het dashboard toont per productcategorie zowel de omzet als het procentuele aandeel in de totale omzet. De aandelen reageren correct op filters en tellen binnen de actieve filtercontext op tot 100%.
PPM-01	Als Product Portfolio Manager wil ik de omzetverdeling per productcategorie en productsubcategorie kunnen analyseren, zodat ik kan beoordelen welke onderdelen van het productportfolio het meest bijdragen aan de omzet.	De omzet wordt in een treemap per productcategorie weergegeven. De gebruiker kan doorklikken naar productsubcategorieën en de selectie werkt door op de gerelateerde visualisaties.

PPM-02	Als Product Portfolio Manager wil ik kunnen zien welke producten de meeste omzet realiseren, zodat ik de belangrijkste producten binnen het portfolio kan identificeren en hun prestaties kan beoordelen.	Het dashboard toont de Top 10-producten op basis van omzet. Per product worden de omzet, en het aantal verkopen in voorgaand jaar en de verandering hierin in huidig boekjaar weergegeven.
PPM-03	Als Product Portfolio Manager wil ik het verkoopvolume, brutomargepercentage en de omzet van product(sub)categorieën met elkaar kunnen vergelijken, zodat ik onderscheid kan maken tussen volumeproducten en margeproducten.	Verkochte aantallen en brutomargepercentage worden per productsubcategorie in één scatterplot weergegeven. De grootte van de punten vertegenwoordigt de omzet. De scatterplot reageert op de selectie in de treemap.
PPM-04	Als Product Portfolio Manager wil ik kunnen zien welke product(sub)categorieën groeien of teruglopen ten opzichte van het voorgaande jaar, zodat ik positieve en negatieve ontwikkelingen binnen het productportfolio kan herkennen.	Het dashboard toont per productsubcategorie de procentuele omzetverandering ten opzichte van het voorgaande jaar. Positieve en negatieve veranderingen zijn visueel van elkaar te onderscheiden.
PPM-05	Als Product Portfolio Manager wil ik inzicht hebben in de verdeling van de kosten over producenten, zodat ik kan bepalen bij welke producenten kostenbesparingen of onderhandelingen mogelijk de meeste impact hebben.	De kosten en het procentuele kostenaandeel worden per producent weergegeven. De visualisatie reageert op de filters en op selecties in de treemap.

Tabel 3 Userstories op basis van de verschillende persona's.

Userstory naar uitwerking

Tabel 4 koppelt elke user story aan de visual in Power BI en Python. Daarmee is de dekking van de tien stories controleerbaar. De Python-versie is bewust eenvoudiger. Hier zijn geen drilldown en geen extra knoppen toegevoegd om te wisselen tussen omzet, kosten en brutomarge. De tabel maakt dat verschil expliciet. PowerBI bevat de meeste mogelijkheden om te filteren, drilldowns toe te passen en de data verder te onderzoeken. Bij Python is gefocust op het namaken van de visualisaties en creëren van interactiviteit door middel van filters. Gezien het doel van de opdracht niet is om de functionaliteiten van PowerBI volledig te her creëren in Python en omwille van de tijd zijn drilldown features in Python achterwege gelaten.

Story	DoD (kort)	Power BI	Dekking Power BI	Python	Dekking Python
GSM-01	4 KPI's, reageren op filters	4 KPI-kaarten	Volledig	4 KPI's	Volledig
GSM-02	Omzet, kosten en marge per maand/jaar	Lijngrafiek + Trend Metric	Volledig	Lijngrafiek	Gedeeltelijk
GSM-03	GDP versus omzet per land	Scatter	Volledig	Scatter	Volledig
GSM-04	Omzet en marge per kanaal	Staaf	Volledig	Staaf	Gedeeltelijk
GSM-05	Omzet en aandeel per categorie	Donut	Volledig	Donut	Gedeeltelijk
PPM-01	Treemap met drilldown naar subcategorie	Treemap	Volledig	Treemap	Gedeeltelijk
PPM-02	Top 10 met omzet, afzet voorgaand jaar en verandering	Tabel	Volledig	Tabel	Volledig
PPM-03	Scatter per subcategorie, grootte = omzet	Scatter	Volledig	Scatter	Gedeeltelijk
PPM-04	Procentuele omzetverandering per subcategorie	Balk	Volledig	Balk	Gedeeltelijk
PPM-05	Kosten en kostenaandeel per producent	Pie	Volledig	Pie	Gedeeltelijk

Tabel 4 Traceability tabel tussen userstories en uitwerking in PowerBI en Python.

5. Mock-ups

Onderstaand zijn de mockups voor de dashboards gemaakt op basis van de userstories uit hoofdstuk 4. De mockups zijn gemaakt met behulp van mokkup.ai en bedoeld om een impressie te geven van hoe het dashboard ingedeeld zal worden en welke weergaven voor welke userstory gebruikt zullen worden. Waarden in de mockups zijn niet representatief voor de dataset. De uitwerking in PowerBI wordt verder toegelicht in hoofdstuk 6 bevindingen.

Sales dashboard mockup

In Figuur 4 is de mockup van het salesdashboard terug te zien, onderstaand worden deze kort toegelicht.

GSM-01 – KPI Cards

GSM-01 komt terug in de vorm van 4 KPI kaarten die direct inzicht geven in belangrijke ontwikkelingen rondom omzet, kosten en brutomarges over de gehele salesdata. Waarden van het huidige of laatste jaar in de selectie worden vergeleken met waarden van het voorgaande jaar. Met behulp van pijlen en kleuren worden de trend van de KPI's aangegeven, hierbij wordt de procentuele ontwikkeling vermeld. Met behulp van de filters in de linker balk kunnen deze KPI's en andere charts verder gefilterd worden om oorzaken verder te analyseren op basis van continent, land, kanaal of productcategorie.

GSM-02 – Revenue by Month

GSM-02 wordt gevisualiseerd met een lijngrafiek. De lijngrafiek leent zich goed om ontwikkelingen in bepaalde periodes met elkaar te vergelijken. Iedere aparte lijn representeert een jaar. Met behulp van knoppen voor "*revenu*", "*cost*" en "*gross margin*" kunnen de verschillende attributen van de KPI's verder geanalyseerd worden.

GSM-03 – GDP per capita versus revenue

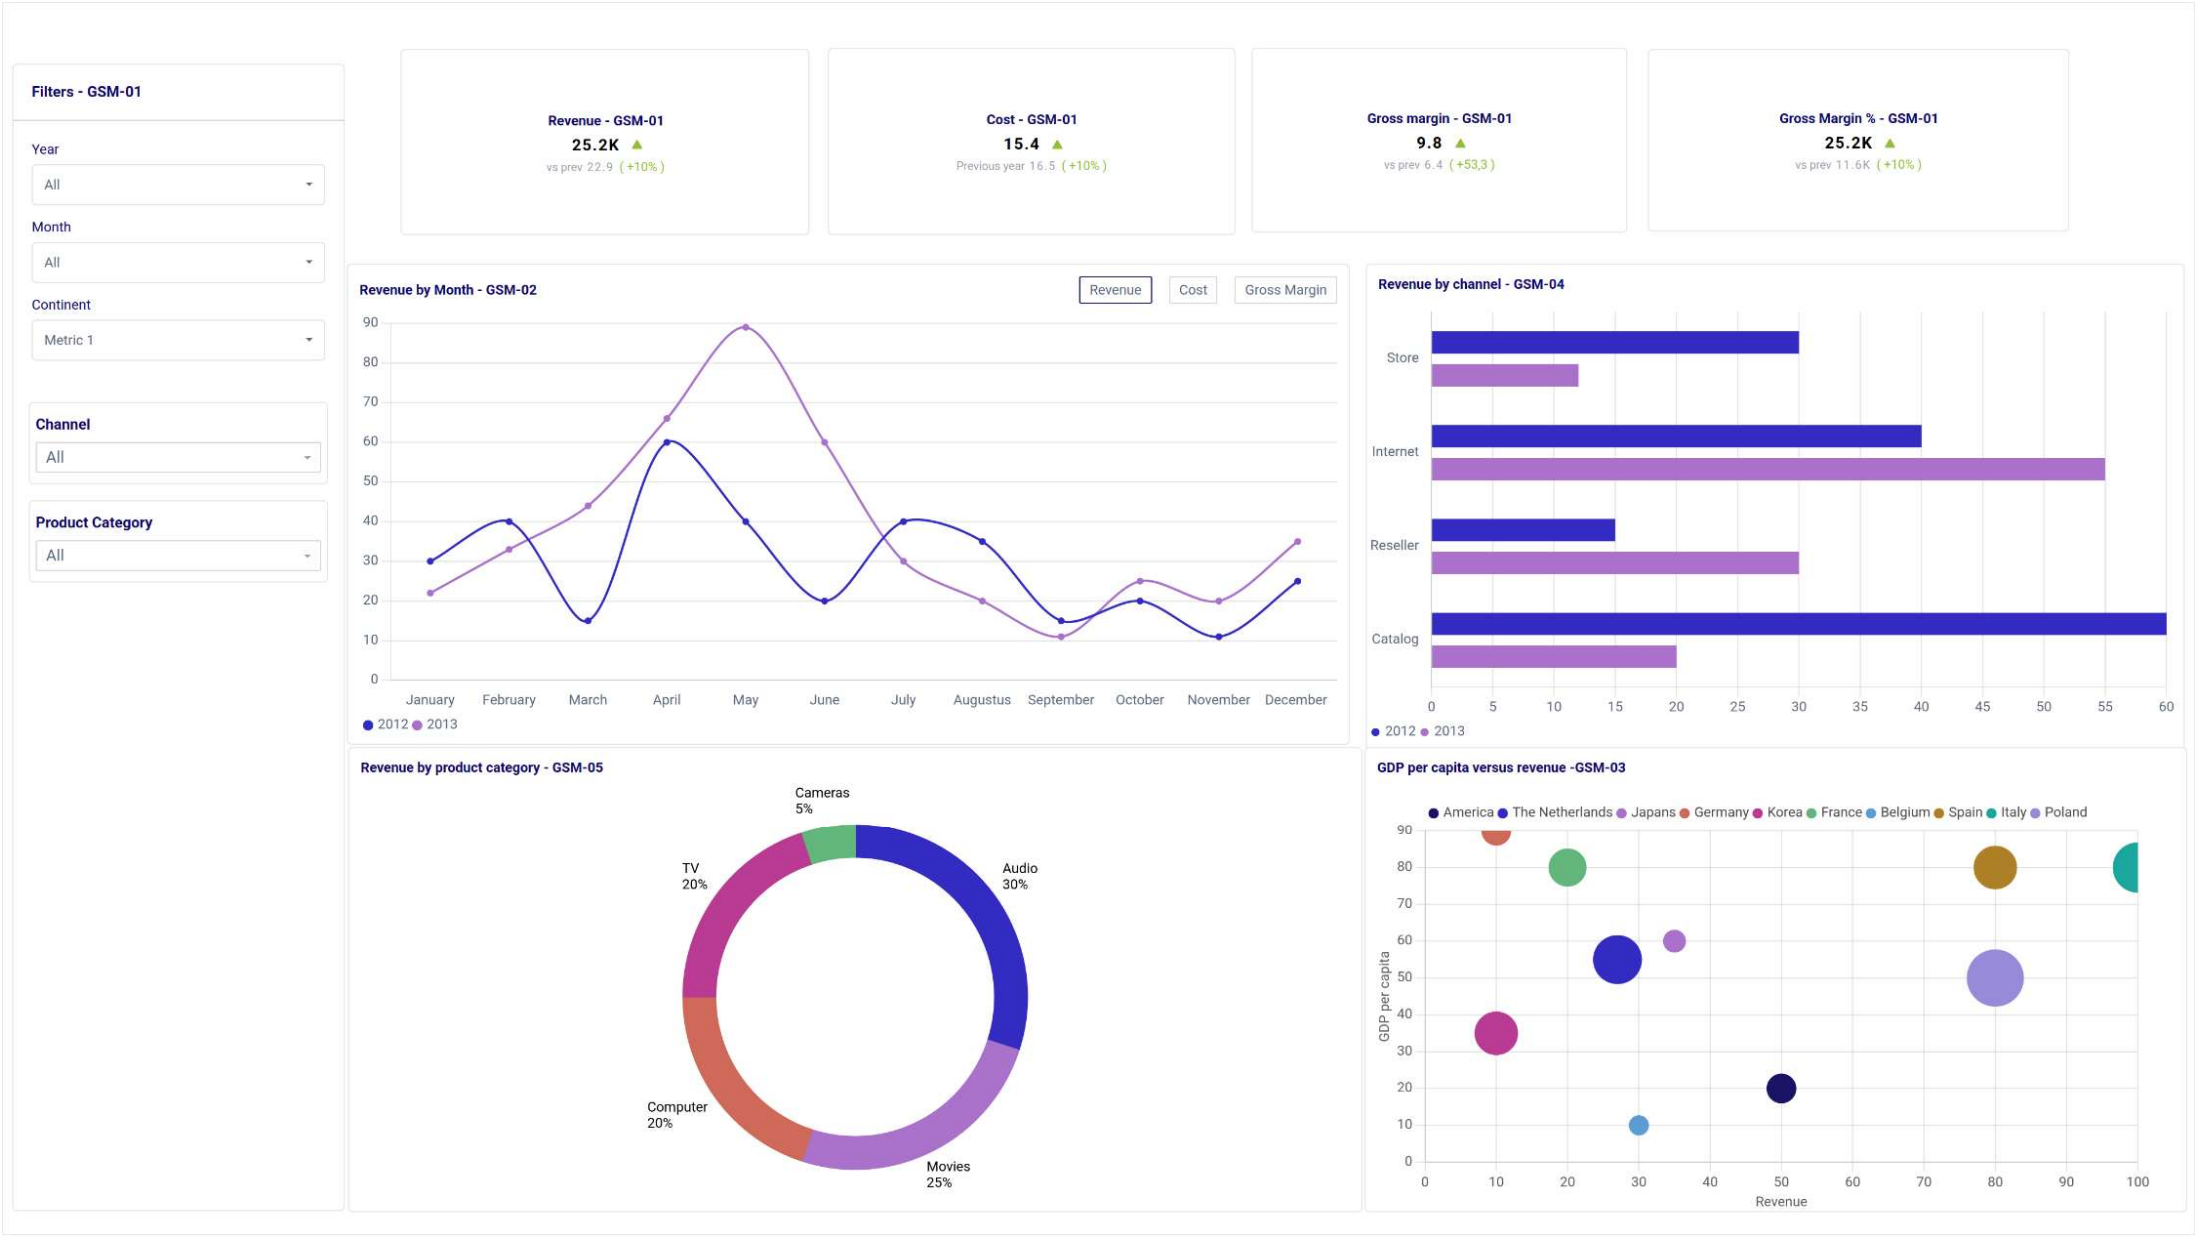
GSM-03 wordt met een scatterchart uitgebeeld. Op de y-as wordt de waarde van het GDP per capita gemeten, op de x-as de omzet. De verschillende bubbels betreffen de landen en de grootte wordt bepaald door de brutomarge. De hypothese die hier getest wordt is dat landen met een hoger GDP meer omzet representeren voor Contoso en dus ook meer opleveren onder aan de streep. Daarnaast kan geanalyseerd worden of stijgingen in GDP voor een land ook leiden tot een stijgende omzet voor Contoso.

GSM-04 – Revenue by channel

GSM-04 laat in een horizontale barchart zien hoe verschillende verkoopkanalen per jaar presteren. Op deze wijze wordt snel zichtbaar of bepaalde kanalen zich sneller ontwikkelen dan andere. Wat tot nieuwe actiepunten of vragen kan leiden die uitgezet dienen te worden binnen de organisatie.

GSM-05 – Revenue by product category

GSM-05 analyseert de samenstelling van het revenu, cost of gross margin voor de geselecteerde periode verdeeld in productcategorieën. Door categorieën te selecteren kan geanalyseerd worden welke categorieën zich ontwikkelen en welke achterblijven of teruglopen in hun bijdrage aan de doelstellingen.



Figuur 4 Mock up salesdashboard.

Product portfolio dashboard mockup

In Figuur 5 is de mockup van het product portfolio dashboard terug te zien, onderstaand worden deze kort toegelicht. Hoewel de KPI-kaarten en filters geen aparte userstory betreffen voor de productportfolio manager is ervoor gekozen deze toe te voegen als belangrijke gegevens. De cost KPI is hierbij vervangen door een sales quantity KPI.

PPM-01 – Revenue by product category

PPM-01 betreft een treechart die de omzetverdeling per productcategory laat zien. Er kan een drilldown op de treechart gedaan worden, waardoor de subcategorieën van deze productcategory zichtbaar worden en hun aandeel in de omzet. De selecties en drilldowns binnen deze chart filteren ook de andere charts op het dashboard om deze verder te kunnen analyseren.

PPM-02 – Top 10 products by revenue

PPM-02 betreft een lijst met de top 10 producten met bijbehorende omzet en brutomarge in percentage. Met behulp van deze gegevens kan de portfolio manager in gesprek gaan met producenten of leveranciers om te onderhandelen over prijzen en afname hoeveelheden. Uiteindelijk is in de definitieve versie de brutomarge vervangen door het aantal verkopen ten opzichte van het voorgaande jaar en de verandering in het huidig jaar. Dit geeft meer informatie voor de product portfolio manager.

PPM-03 – Gross margin versus sales quantity

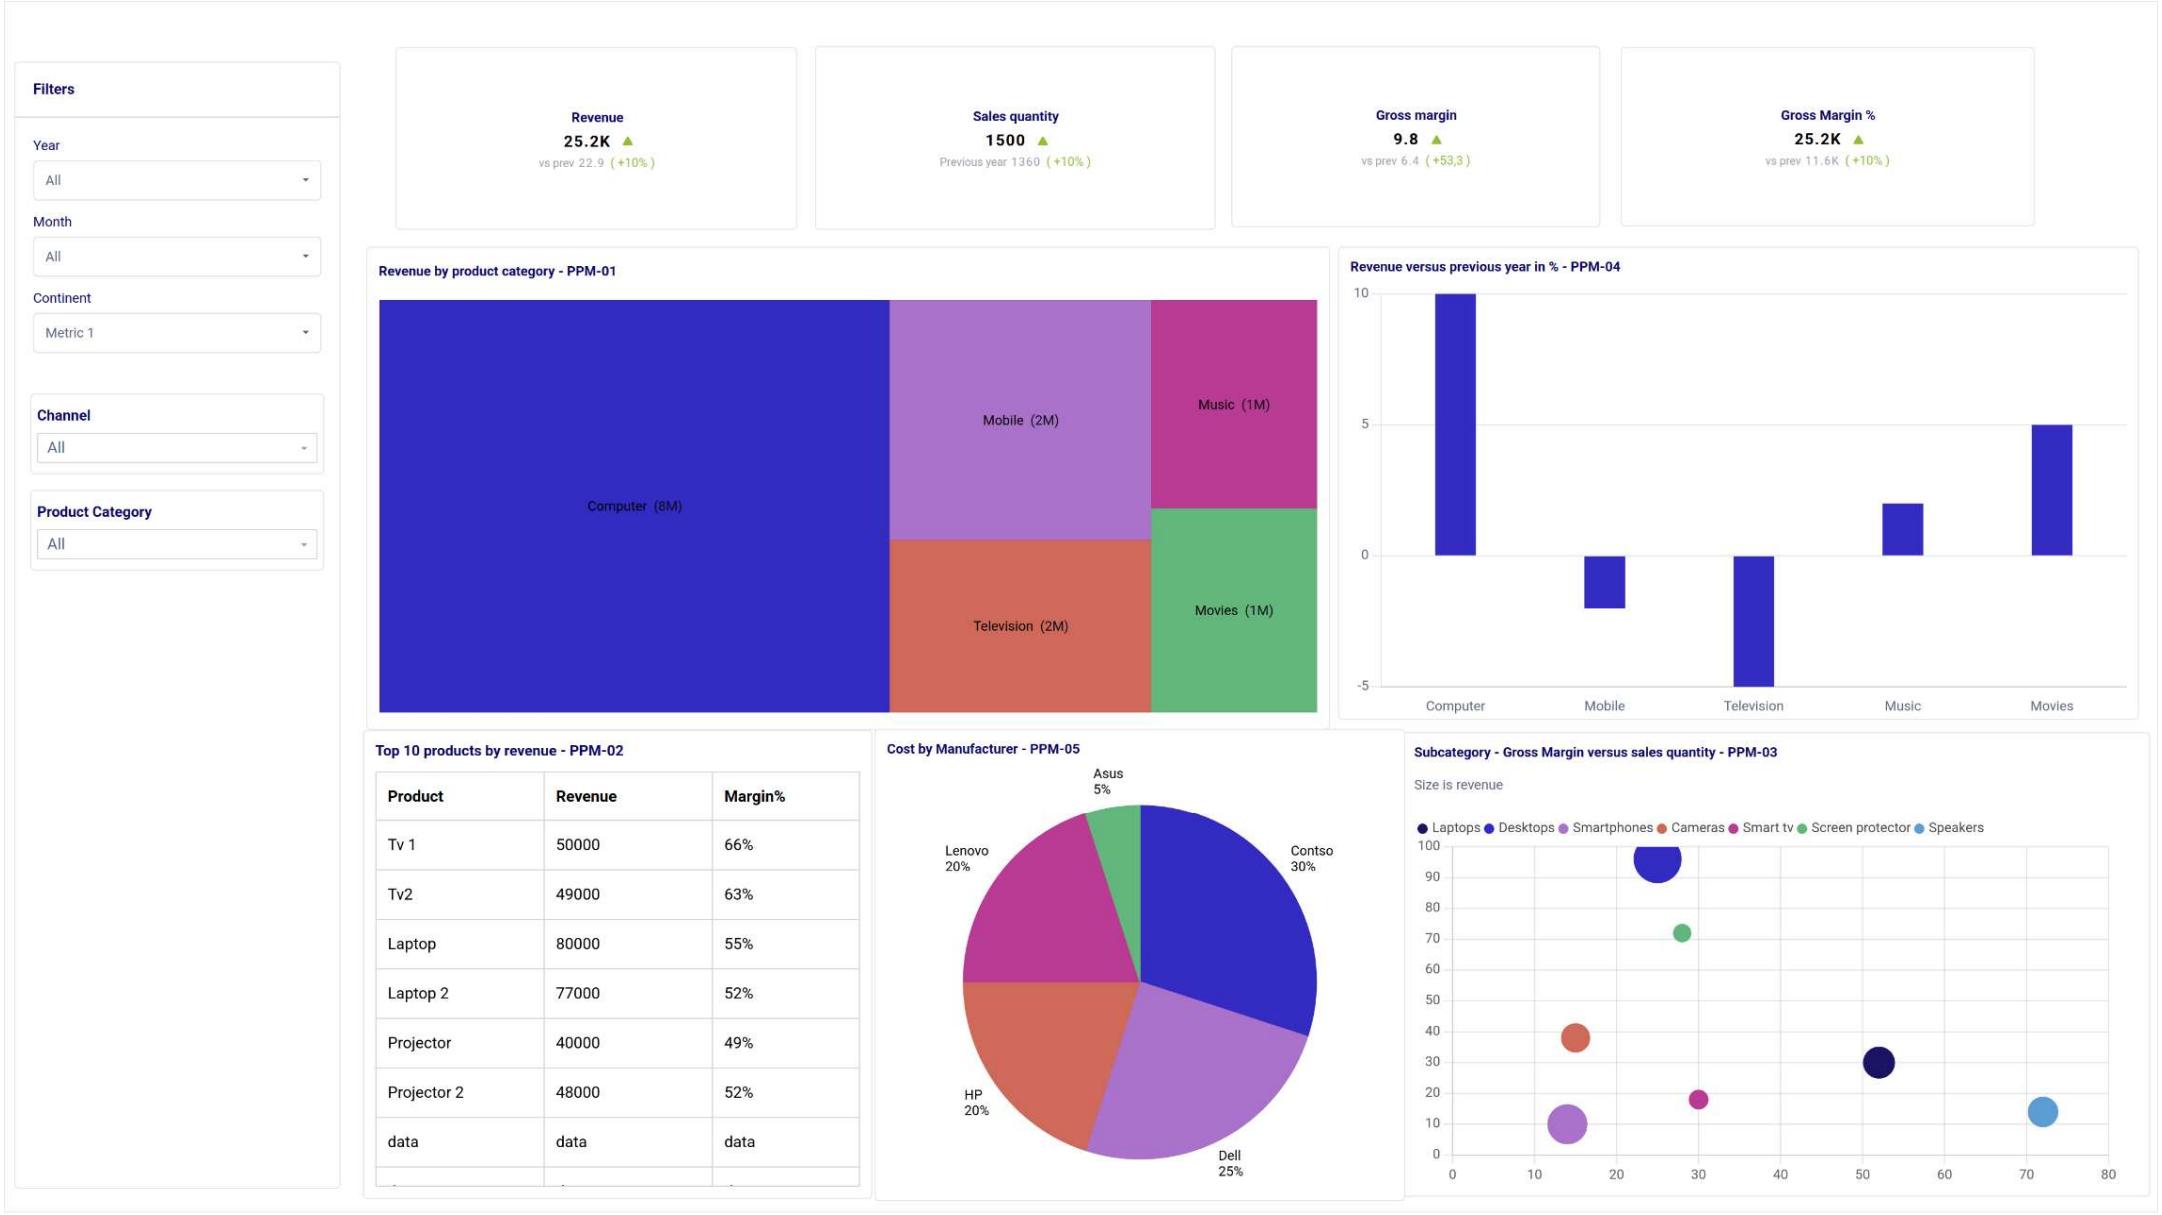
PPM-03 betreft een scatterchart die de sales quantity afzet tegen de brutomarge in percentage. De Y-as drukt de gross margin uit in percentage en de X-as de sales quantity in hoeveelheden. De bubbels representeren product subcategorieën en de grootte wordt bepaald door de omzet. Analyses laten zo snel zien welke subcategorieën veel omzet representeren, met welke marge en in welke hoeveelheid ze verkocht worden.

PPM-04 - Revenue versus previous year in %

PPM-04 betreft een horizontale barchart die de omzetstijging of -, daling per productcategorie of subcategorie laat zien. Dit stelt de product portfolio manager om te analyseren welke producten beter of slechter presteren, welke markten zich aan het ontwikkelen zijn en welke producten eventueel uitgefaseerd dienen te worden.

PPM-05 – Cost by manufacturer

PPM-05 is een piechart die voor de geselecteerde productcategorie, productsubcategorie of product de kosten per producent laat zien, waarvan wordt aangenomen dat deze gelijk is aan de leverancier. Op basis van deze gegevens kan de portfolio manager in gesprek met producenten om de kosten van producten te drukken.

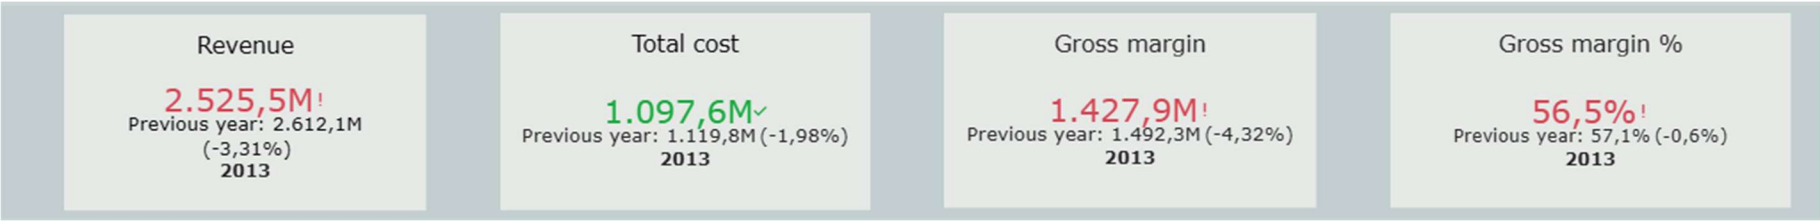


Figuur 5 Mockup product portfolio dashboard.

6. Bevindingen

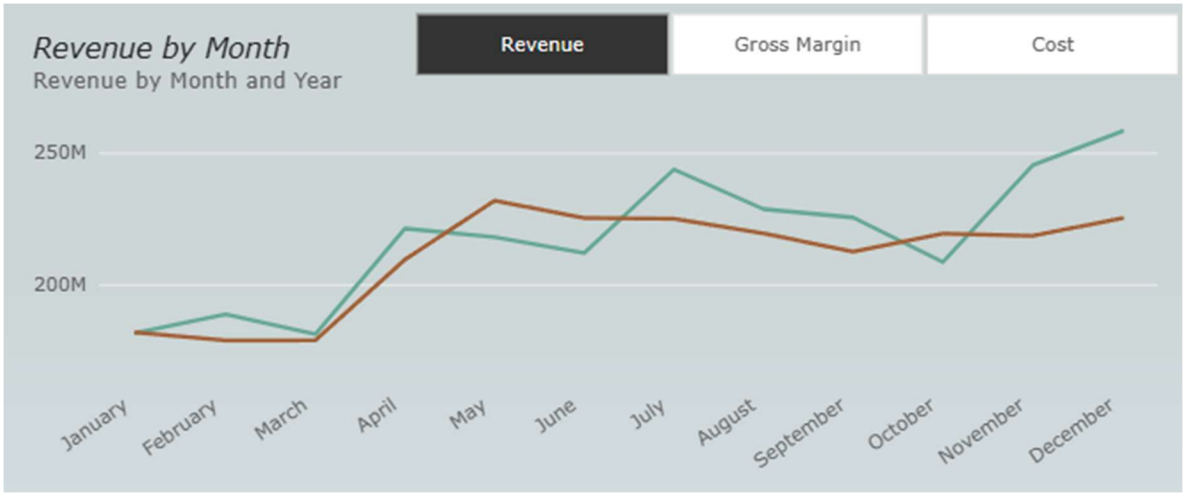
In deze paragraaf worden de bevindingen van de twee dashboards gecreëerd in PowerBI vastgelegd. Dit wordt gedaan vanuit het perspectief van de eerder opgesteld persona's en hoe zij het dashboard kunnen toepassen om inzichten te verkrijgen in de salesdata.

Sales dashboard



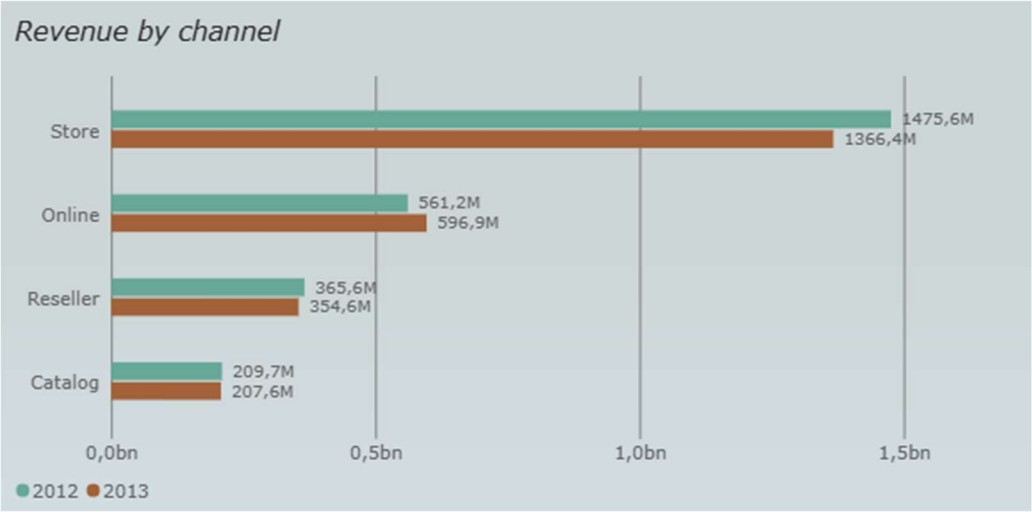
Figuur 6 De 4 KPI-kaarten die inzicht geven in de omzet, kosten, brutomarge en brutomarge uitgedrukt in percentage. De waarden betreffen die van het laatste jaar uit de selectie (2013) en vergelijkt deze met het voorgaande jaar (2012).

Zodra de salesmanager het dashboard opent ziet hij bovenaan de vier KPI-kaarten die de laatste ontwikkelingen laten zien. Er valt te zien dat de omzet tegenover 2012 met 3,31% is gedaald en het brutomargepercentage is met circa 0,6 procentpunt gedaald ten opzichte van voorgaand jaar. Dit is een signaal voor verder onderzoek naar de oorzaak hiervan. Met behulp van de filters in de linker balk kunnen de jaren 2012 en 2013 geselecteerd worden om de vergelijkende gegevens te beperken tot deze twee boekjaren.

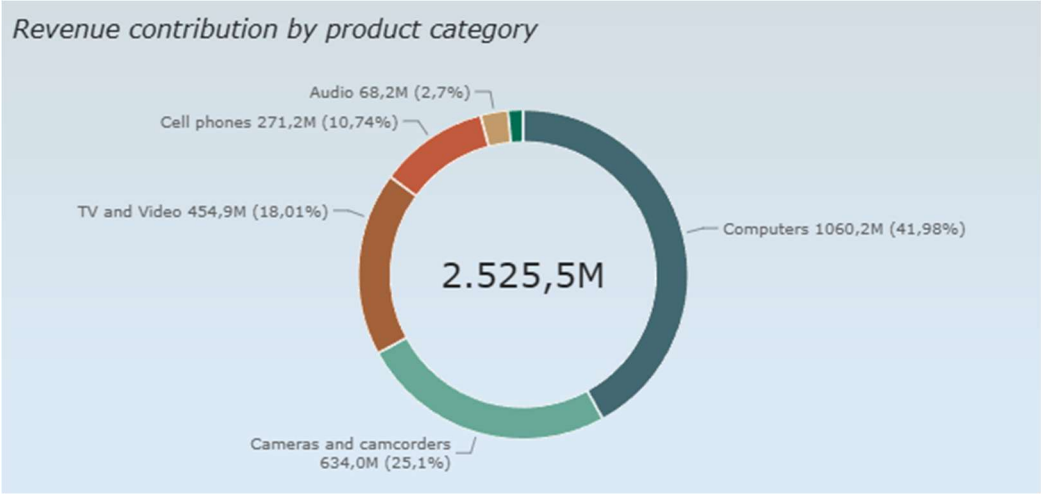


De lijngrafiek; *Revenue by Month,* onder de KPI's laat zien dat de prestaties in 2013 bijna het gehele jaar achterblijven op die van 2012. Met name in de periode van juli tot en met september en november en december wordt er minder omzet behaald dan voorgaand jaar. Vanuit de tijdlijn blijkt niet direct wat deze wisseling veroorzaakt. Wellicht komt dit door promoties of externe factoren.

Figuur 7 Revenue by Month is een lijngrafiek die de omzet per maand weergeeft. Eén of meerdere jaren kunnen vergeleken worden met behulp van deze grafiek. De knoppen kunnen gebruikt worden om te wisselen tussen Revenue, Gross Margin en Cost. Andere grafieken reageren ook op deze knoppen.



Figuur 8 Revenue by channel is een barchart die omzet, kosten en brutomarge per verkoopkanaal kan vergelijken.

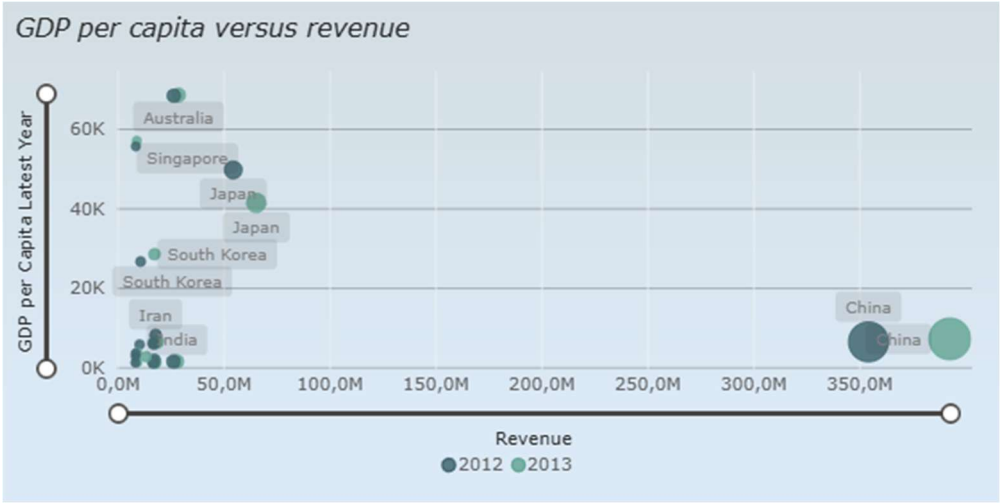


Figuur 9 Revenue contribution by product category laat de omzetverdeling per productcategorie zien. Door productcategorieën te selecteren worden de andere grafieken gefilterd en kunnen ontwikkelen op product categorieniveau geanalyseerd worden.

De barchart; *Revenue by channel,* naast de lijngrafiek laat zien dat met name stores afnemende omzet ervaren, terwijl online verkopen juist een groeiend verkoopkanaal zijn binnen de dataset. Als er gefilterd wordt op online als verkoopkanaal laat de GDP chart zien dat er via dit kanaal enkel in de Verenigde Staten, Duitsland en China afzet plaatsvindt via deze wijze, waarbij China de meeste groei laat zien. Een actiepunt uit deze bevinding is om in overleg met marketing te onderzoeken welke kansen er liggen in het uitbreiden van de verkopen via onlinekanalen.

Ongeacht het verkoopkanaal laat de donutchart; "*Revenue contribution by product category"* ongeveer dezelfde omzetsamenstelling per verkoopkanaal zien. De meeste omzet, ca. 40%, komt voort uit de categorie *computers*. De andere grafieken op het dashboard onderbouwen ook dat dit een stabiele productcategorie is waar producten een omzetgroei laten zien van 8% met een stabiele marge.

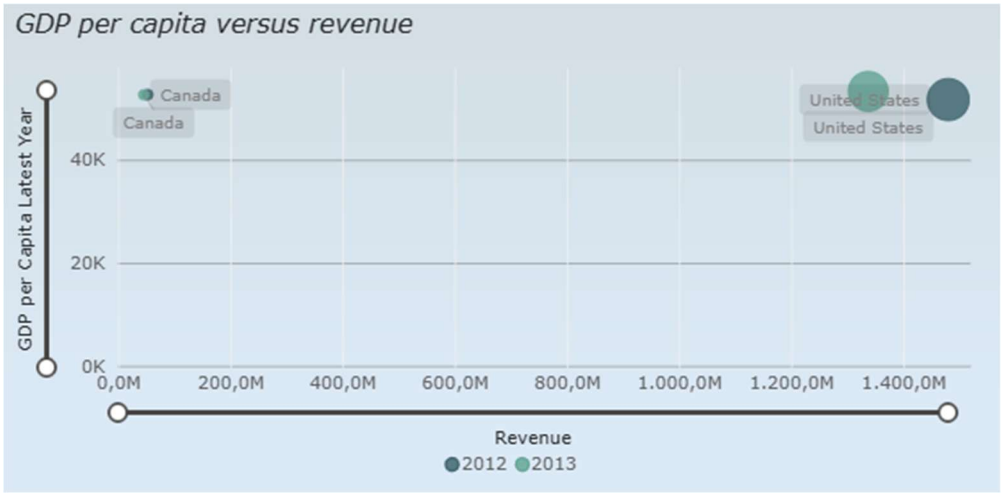
Als er ingezoomd wordt op *cameras and camcorders* laat het dashboard een ander beeld zien. De omzet is met ca. 21,5% afgenomen t.o.v. voorgaand jaar. Gezien het aandeel van 25% in de totale omzet van het boekjaar 2013 verklaart deze daling ook voor een groot deel de dalende omzetcijfers voor dit boekjaar. De *revenue by month grafiek* onderbouwt deze analyse doordat een filter op deze categorie laat zien dat de omzet bijna iedere maand ca. 10 miljoen achterblijft op voorgaand jaar. Daarnaast volgt de omzetpiek in november en december 2012 bijna één op één het patroon van de algehele omzet. Een actiepunt is om verder te onderzoeken welke productsubcategorieën en specifieke producten deze daling veroorzaken.



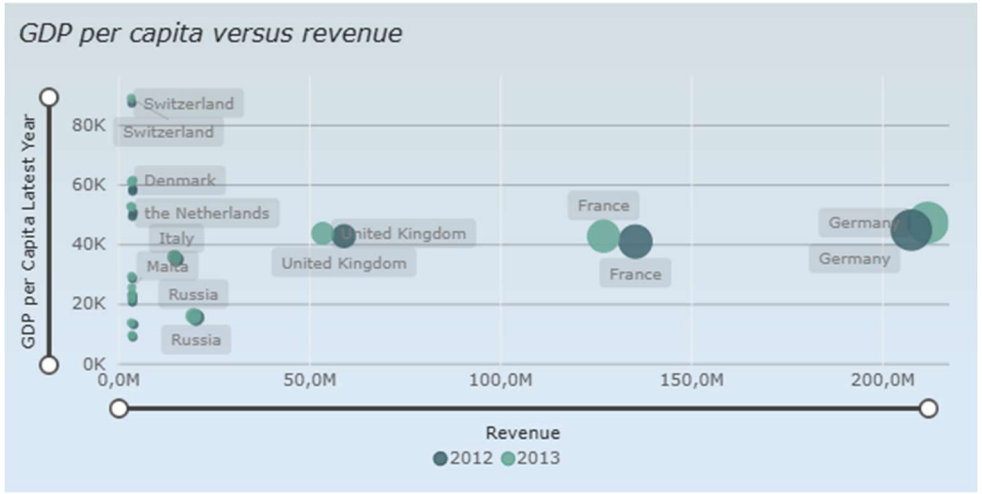
Figuur 10 GDP per capita versus revenue Azië.

Met de scatterchart; *GDP per capita versus revenue*, wordt er gekeken naar het verband tussen de mutaties van GDP per inwoner tegenover de omzetgroei. In Azië valt te zien dat een stijging in GDP per inwoner vaak samengaat met stijgende omzetten. Met name China is hierin een interessante markt, een stijging van het GDP per inwoner met ongeveer 500 dollar gaat gepaard met een stijging van bijna 11% omzet.

Als er naar de twee andere continenten gekeken wordt, lijkt het tegenovergestelde het geval. Zowel Europa als Noord-Amerika laten bij een stijgende GDP per inwoner dalende omzetten zien voor Contoso. Een stijgende GDP per inwoner gaat dus niet altijd gepaard met stijgende omzet. Er dient dus onderzocht te worden welke andere interne en externe factoren hier invloed op hebben.

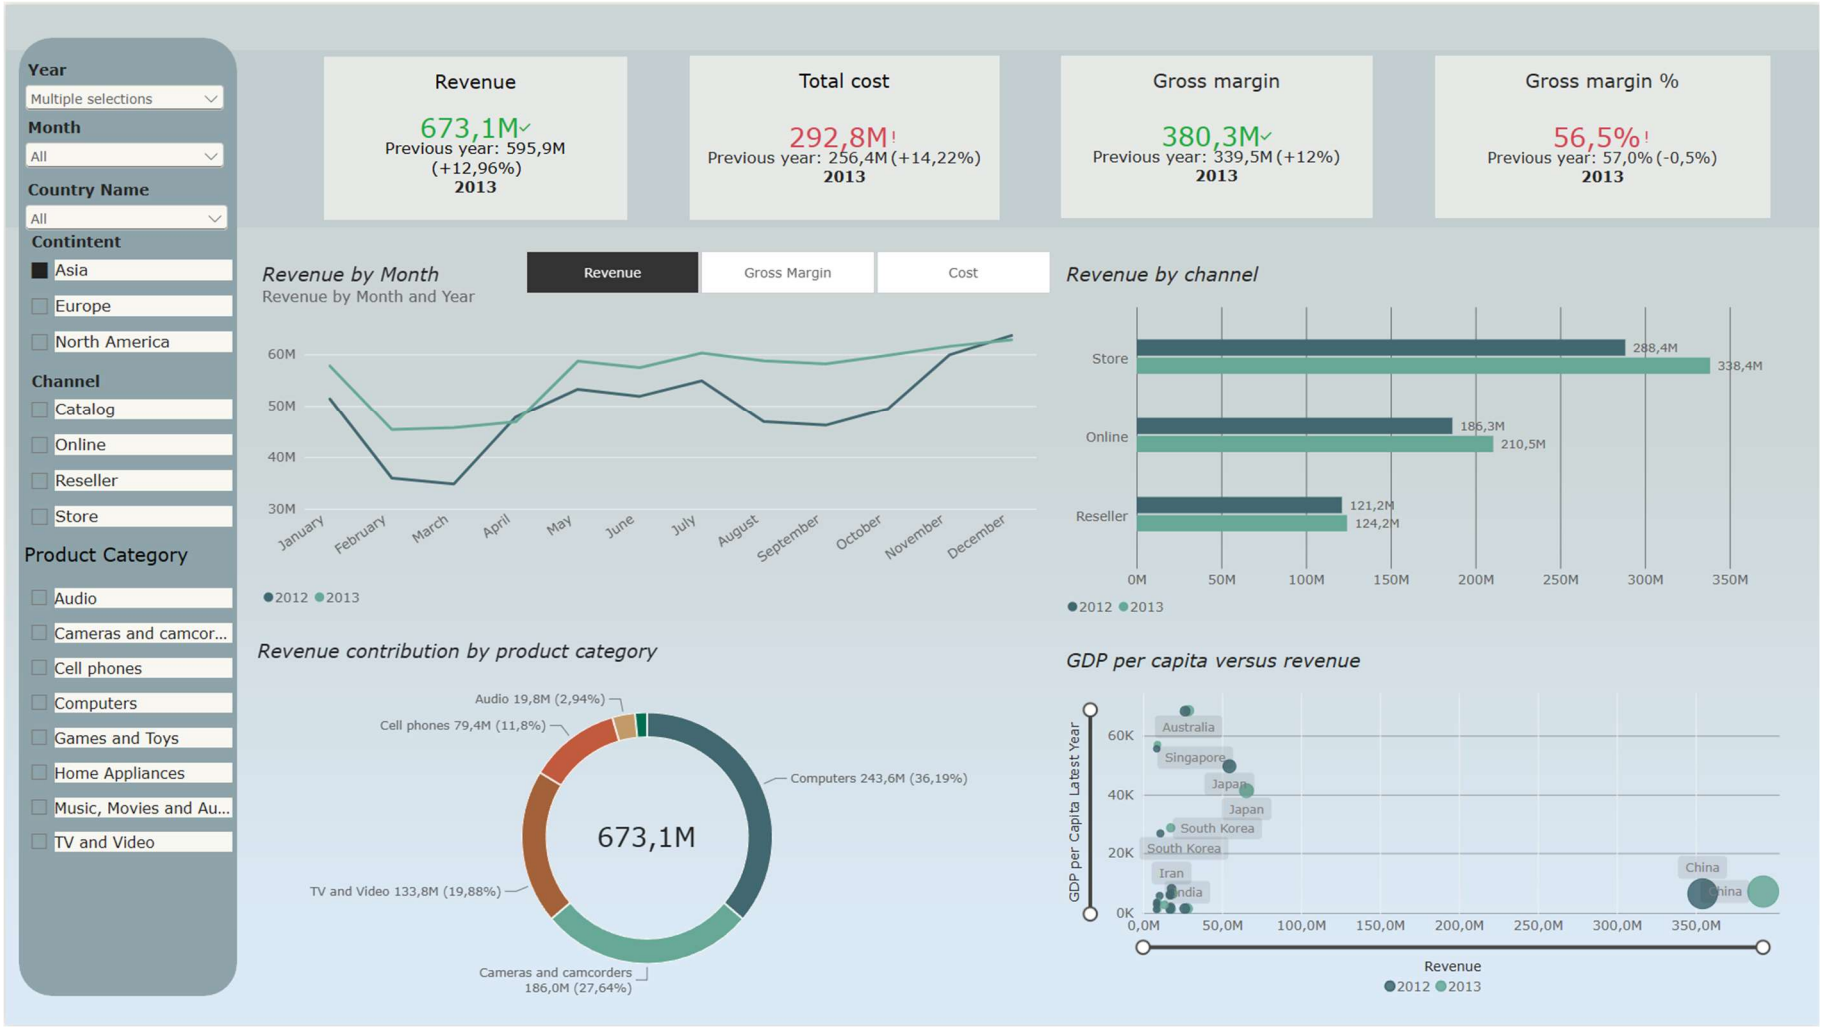


Figuur 12 GDP per capita versus revenue Noord-Amerika.



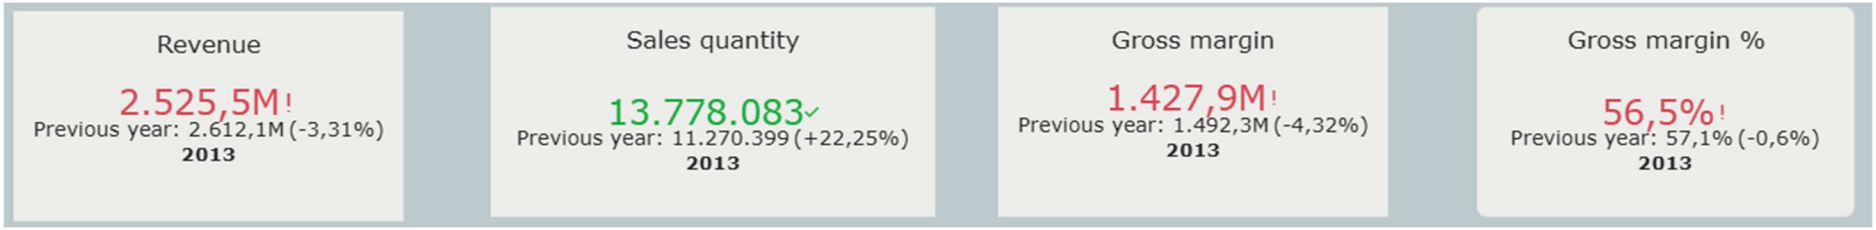
Figuur 11 GDP per capita versus revenue Europa.

Toepassing van de continentfilter bevestigt ook de groeiende Aziatische markt voor Contoso. In contrast tot de algehele omzetdaling in 2013, laat deze markt juist groei zien. Verdere omzetgroei in Azië onderzoeken is hier dan ook een kans. Hiertegenover staat een uitdaging in Noord-Amerika waar minder fysieke verkopen en teruglopende camera, tv en media verkopen tot bijna 10% omzetverlies leiden.



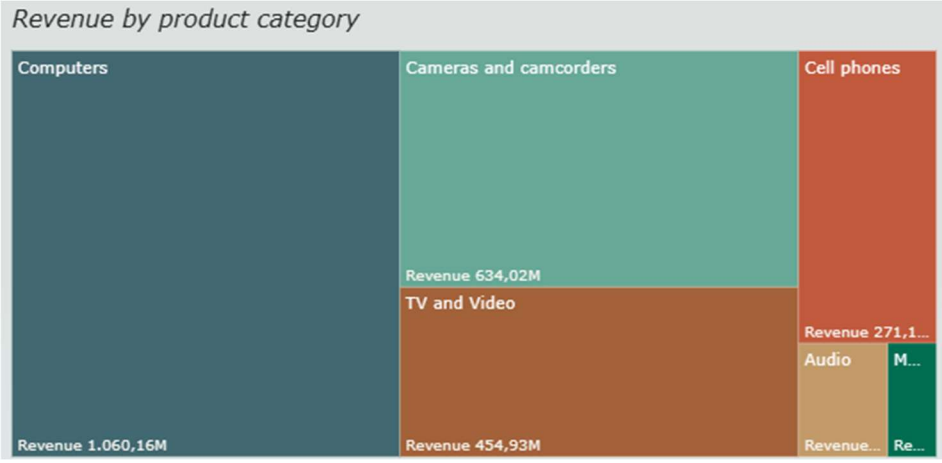
Figuur 13 Het salesdashboard gefilterd op continent Azië.

Product portfolio dashboard

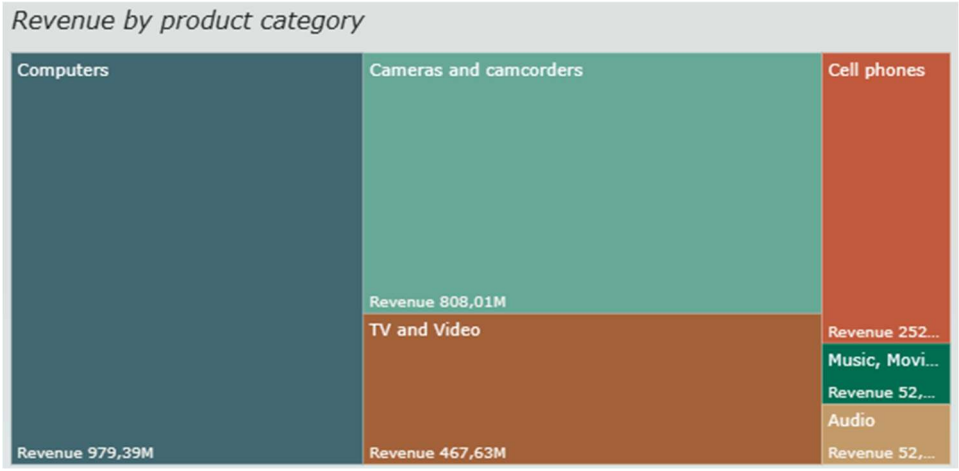


Figuur 14 De 4 KPI-kaarten die inzicht geven in de omzet, aantal verkopen, brutomarge en brutomarge uitgedrukt in percentage. De waarden betreffen die van het laatste jaar uit de selectie (2013) en vergelijkt deze met het voorgaande jaar (2012).

Net als bij de salesmanager heeft de product portfolio manager bovenaan het dashboard 4 KPI kaarten. Hier is ervoor gekozen de Cost-kaart te vervangen door Sales quantity, zodat de product portfolio manager inzicht heeft in verkochte hoeveelheden, zowel op totaal niveau als per productcategorie en subcategorie bij gebruik maken van drill downs en filters. Het eerste opvallende signaal is dat ondanks afnemende omzetten, het aantal verkochte producten significant is gestegen. Dit is een indicatie dat er een verschuiving plaatsvindt in de verkoopmix van verkochte goederen. Een eerste aanname is dat er meer relatief goedkope producten verkocht worden tegenover voorgaand jaar.



Figuur 16 Treechart met omzet per productcategorie voor het jaar 2013.



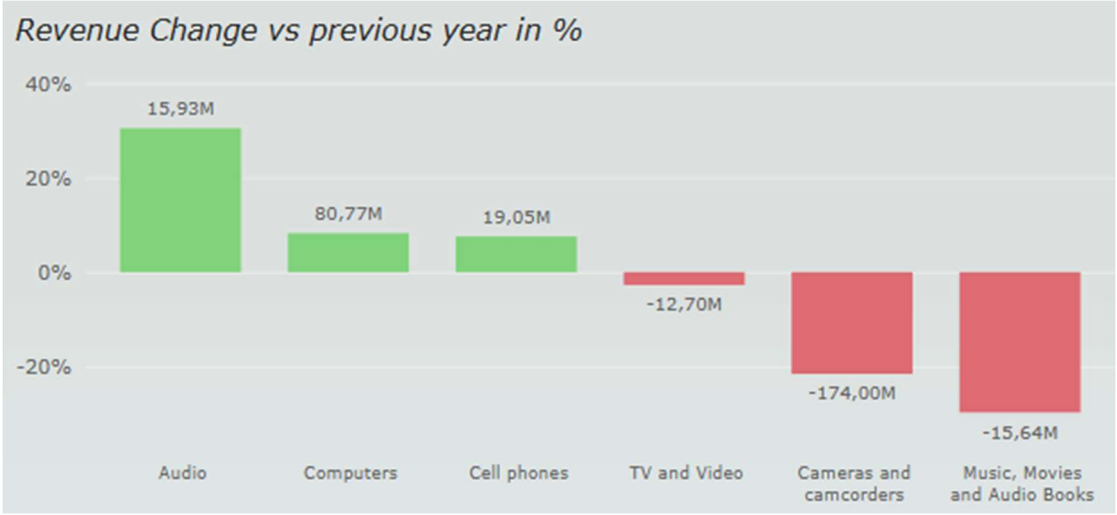
Figuur 15 Treechart met omzet per productcategorie voor het jaar 2012.

De *Revenue by product category* treechart stelt de portfolio manager in staat snel verschillen tussen omzet samenstelling te zien op basis van verschillende filters. In Figuur 15 en Figuur 16 is terug te zien dat conform de analyse uit het salesdashboard de omzet uit cameras en camcorders in 2013 sterk achteruitloopt. Daarentegen stijgen de omzet en het aandeel van de categorieën telefoons en audio.

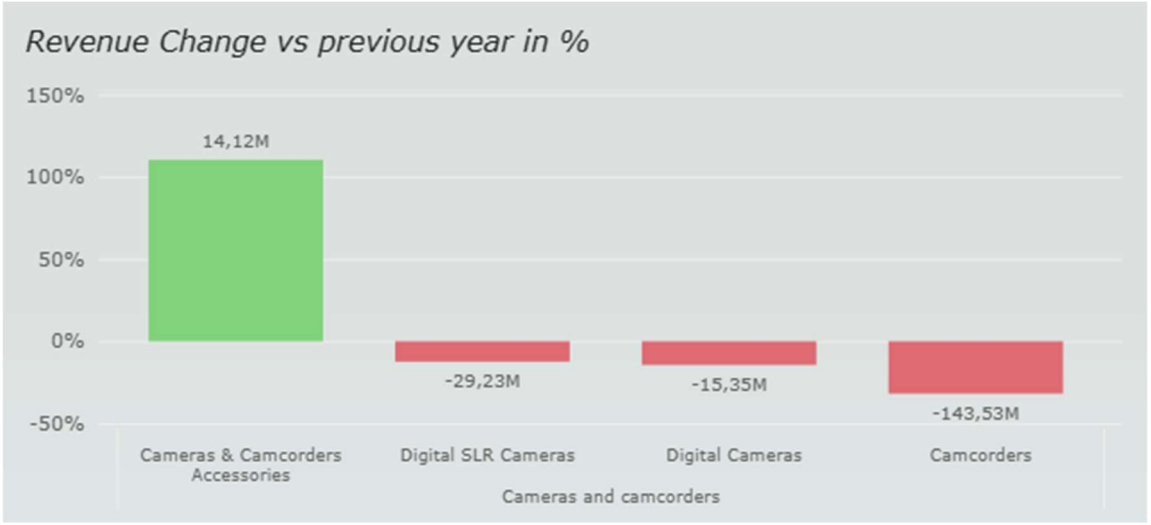
Revenue Change vs previous year in % maakt deze wisselingen met behulp van een horizontale barchart duidelijk zichtbaar. Omzetstijgingen worden als groene balken gepresenteerd, daling in het rood.

Met behulp van de drilldown functie kan ingezoomd worden op de subcategorieën waaruit de categorie bestaat, zoals te zien in Figuur 18. Procentueel gezien is er een sterke omzetstijging t.o.v. voorgaand jaar in de subcategorie *Cameras & Camcorders Accesoires*. Echter is de absolute omzetstijging van ca. 14 miljoen euro relatief laag. Daar komt bij kijken dat er voor deze omzetstijging ca. 180.000 extra stuks verkocht diende te worden.

In contrast loopt de omzet uit verkoop van camcorders terug met ca. 143 miljoen euro, wat grotendeels een verklaring lijkt voor de omzetdaling in 2013. Hier komt bij dat de omzetdaling in 2012 voor deze categorie nog groter was. Het is een actiepunt voor de portfolio manager om te onderzoeken of cameras en camcorders nog wel een geschikt product zijn binnen het portfolio van Contoso.



Figuur 17 Revenue change vs previous year in % laat met behulp van gekleurde balken snel zien welke productcategorieën omzetstijgingen en dalingen vertonen. De absolute bedrage worden in miljoenen vermeld.



Figuur 18 Een drilldown in de categorie "cameras and camcorders" laat zien dat cameras and camcorders ten opzichte van het vorige jaar aanzienlijk minder omzet opleveren.

Top 10 products by revenue

Product Name	Revenue	Sales previous year	Sales Change
Contoso Bluetooth Active Headphones L15	€ 23.743.334	0	182.980
Adventure Works Laptop8.9 E0890	€ 29.688.487	25.127	67.131
Fabrikam SLR Camera 35" M358	€ 24.456.756	49.523	26.111
Adventure Works Laptop16 M1601	€ 26.117.826	25.102	19.662
Adventure Works Laptop15.4W M1548	€ 31.764.119	23.658	19.386
Adventure Works Laptop15 M1501	€ 29.319.702	24.664	18.416
Adventure Works Laptop19W X1980	€ 44.389.064	24.217	11.128
Adventure Works 52" LCD HDTV X590	€ 24.489.836	0	8.761
WWI Laptop19W X0196	€ 23.702.268	18.451	413
Proseware Projector 1080p DLP86	€ 24.136.192	17.786	-7.758

Figuur 19 Lijst van top 10 producten.

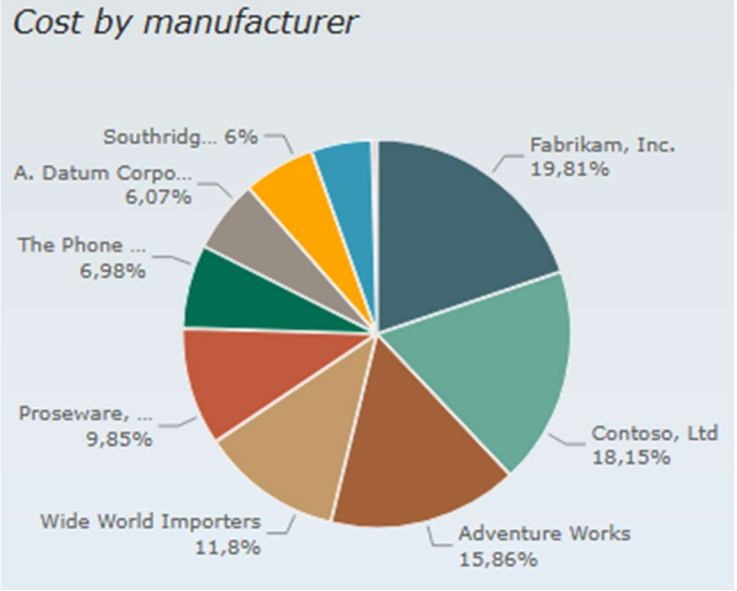
De top 10 products by revenue laat in een tabel de producten van Contoso zien die de meeste omzet opleveren. Daarnaast worden de verkopen uit voorgaand jaar en het verschil in verkopen ten opzichte van voorgaand jaar weergegeven. De analyse laat zien dat één van de meest verkochte producten de nieuwe bluetooth koptelefoon van Contoso is. Met een omzet van ca. 23,7 miljoen euro en een afzet van bijna 183.000 eenheden verklaart dit ook de omzetstijging binnen de categorie audio.

De helft van de lijst bestaat tevens uit producten van de leverancier Adventure Works. Dit kan een goed aanknooppunt zijn in eventuele onderhandelingen over kortingen of prijsafspraken met de leverancier.

Aansluitend op deze bevinding laat de piechart *Cost by Manufacturer* zien welke deel van de kosten verschillende fabrikanten representeren voor de productcategorieën in de dataset.

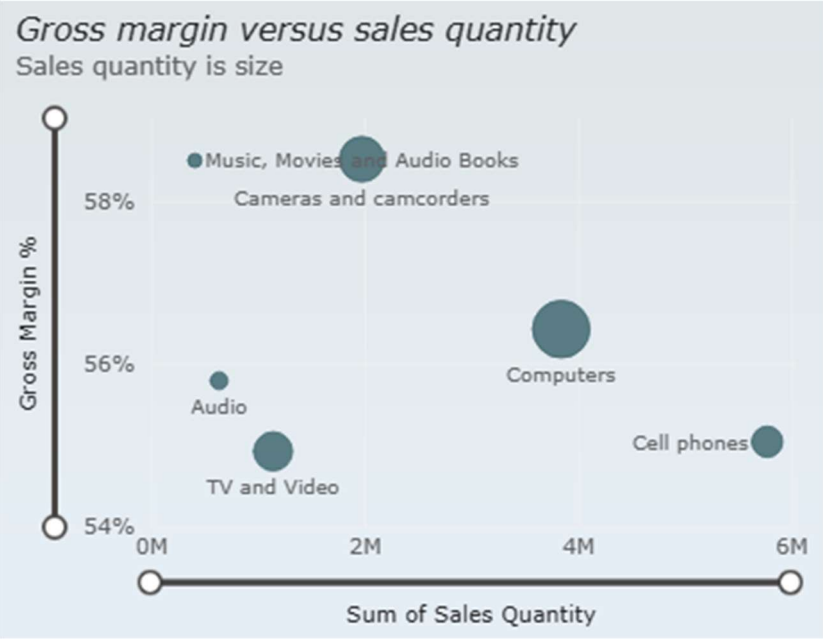
Fabrikam, Inc. is de grootste leverancier van Contoso. Het dashboard laat zien dat deze leverancier voornamelijk producten uit de categorie *cameras and camcorders levert*. De grootste leverancier van Contoso levert dus de producten die het meeste omzetdaling representeren, met daarbij een verslechterende marge. Het is een actiepunt voor de organisatie om in gesprek te gaan met deze leverancier om kosten van deze producten omlaag te brengen en eventueel een deel van het assortiment uit te faseren.

Bij Adventure Works laat het totale dashboard zien dat er een omzetgroei van bijna 16% op producten van deze leverancier wordt behaald met een toename in de afzet van 10%. Deze cijfers kunnen goed gebruikt worden om eventuele onderhandelingen te onderbouwen.

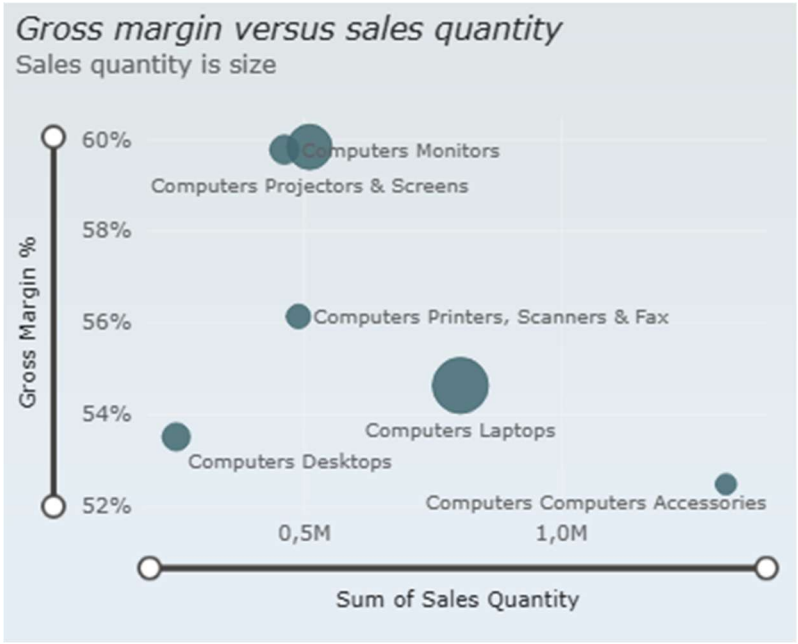


Figuur 20 Piechart die het aandeel in de kosten van iedere fabrikant/leverancier voor Contoso laat zien.

De scatterchart *Gross margin versus sales quantity laat* de relatie zien tussen brutomarge, afzet en omzet zien op productcategorieniveau en bij drilldown op subcategorie niveau. Hierin valt te zien dat de categorie computers een groot deel van de afzet betreft met een gemiddelde marge voor Contoso. De grootte van de bubbel laat zien dat deze het grootste deel totale omzet heeft. Als er een drilldown gedaan wordt naar subcategorie niveau valt te zien dat met name laptops en monitoren het grootste aandeel in deze omzet hebben. Desktops daarentegen hebben tegenover de rest van de categorie een lage marge en afzet.

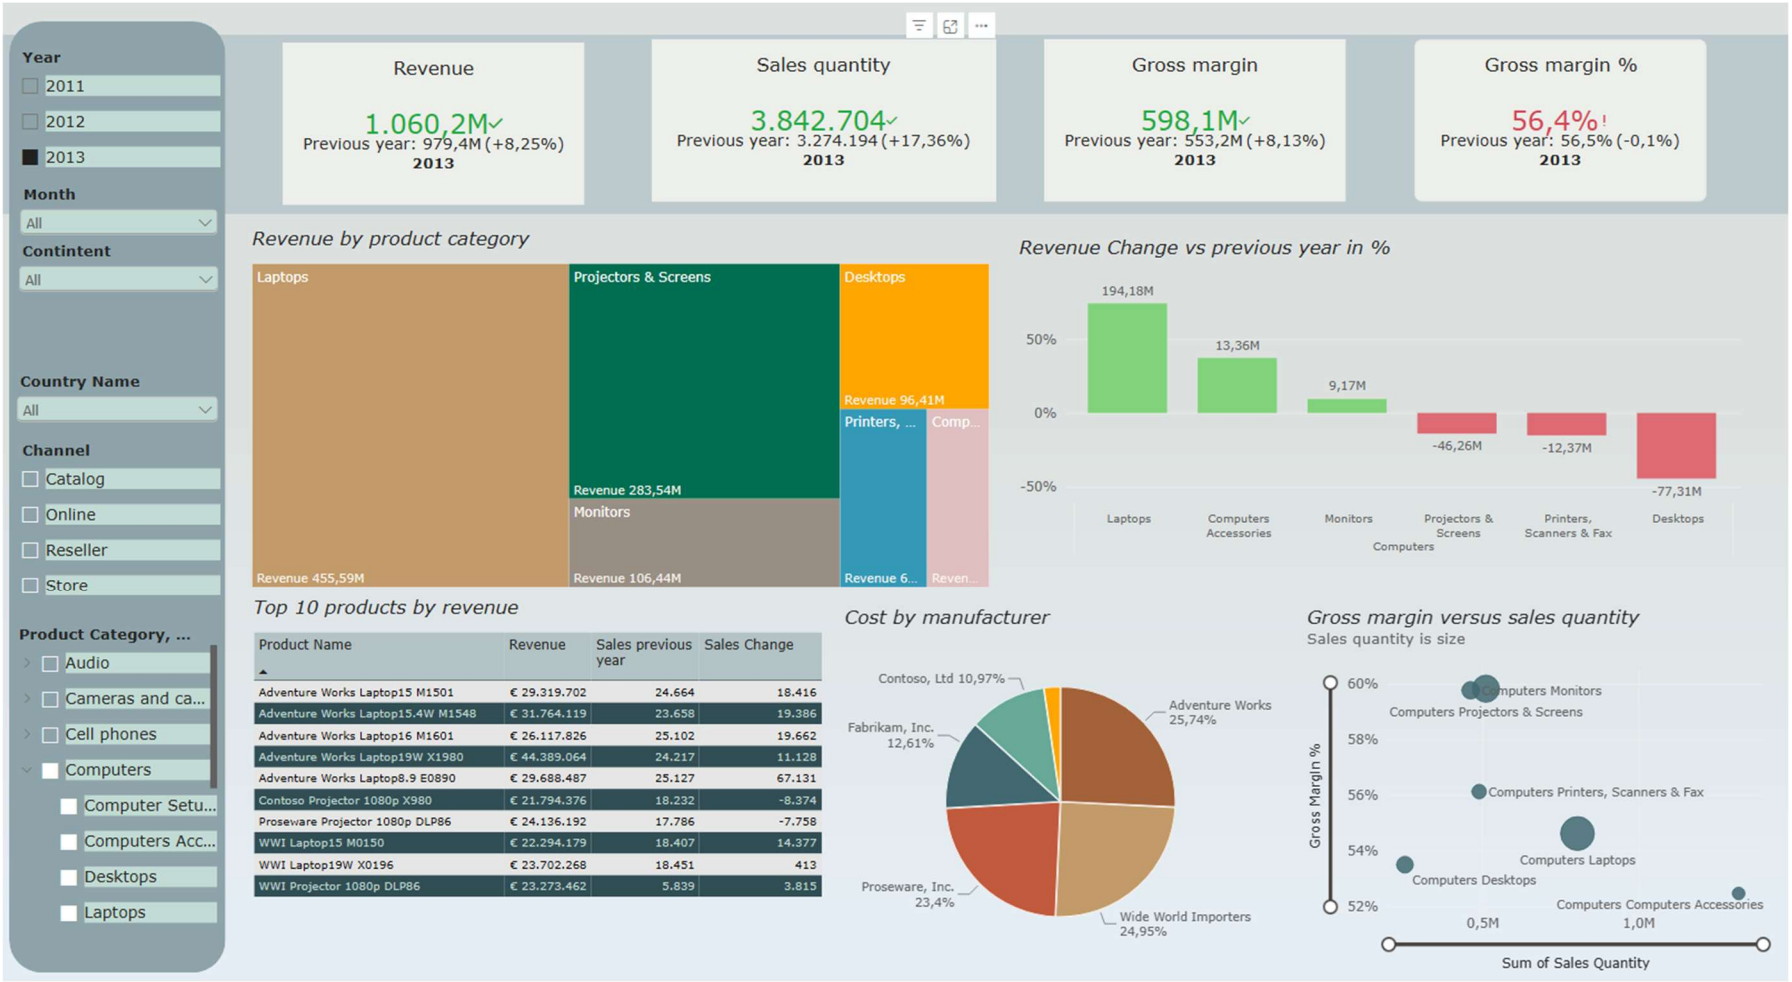


Figuur 22 Gross margin versus sales quantity laat de relatie tussen afzet, brutomarge en omzet zien op productcategorieniveau.



Figuur 21 Gross margin versus sales quantity met een drilldown op de productcategorie computers.

Het dashboard gefilterd op de productcategorie computers bevestigt dat desktops een minder presterend product zijn binnen de categorie. Naar aanleiding van deze inzichten kan de product portfolio manager onderzoeken of afbouw van het assortiment aan desktops en verder investeren in de afzet van laptops een goede richting is voor Contoso.



Figuur 23 Het productportfolio dashboard gefilterd op productcategorie computers.

7. Reflectie

Situatie

De opzet van deze periode was om op basis van de theorie achter Business Intelligence met behulp van PowerBI en Python een ETL-pipeline te creëren die uiteindelijk als bron dient voor een dashboard of andere rapportage laag.

Ter voorbereiding heb ik me voorafgaand ingelezen in de belangrijkste aspecten van pandas voor deze opdracht. Dit heb ik met name gedaan omdat mijn achtergrond niet in de informatica zit en ik hier de grootste uitdagingen zag.

Taak

Mijn taak was om met de aangeboden datasets een pipeline te creëren die uiteindelijk leidt tot een opgeschoonde dataset die bruikbaar is voor rapportages.

Actie

Met behulp van Python, en met name Pandas ben ik begonnen met het analyseren, opschonen en verrijken van de data. Als laatste stap heb ik hier nog validatie aan toegevoegd. Ik heb ervoor gekozen deze vervolgens op te slaan als aparte parquet-bestanden om ruimte te besparen. Vervolgens heb ik op basis van deze bestanden een PowerBI dashboard gecreëerd en hetzelfde dashboard zover mogelijk ook in Python gebouwd. Als laatste is er voor gekozen de pipeline zowel lokaal als via een eigen domein te laten draaien.

Hierbij ben ik deels ondersteund door AI in de vorm van ChatGPT. Mijn werkwijze bestond uit het gericht stellen van vragen rondom functies die ik niet snapte of de basis nog niet voor had gelegd. Hierbij heb ik specifieke instructies gegeven om reacties niet te geven in de vorm van kant en klare stukken code, maar functies die worden opgebouwd met behulp van worked examples en korte uitleg tussendoor.

Resultaat

Het uiteindelijke resultaat is:

- Een notebook met een pipeline die aangepast kan worden om de input voor de dashboards aan te passen, die zowel lokaal als via online imports en exports werkt.
- Een PowerBI dashboard voor de Global salesmanager en product portfolio manager persona's.
- Een notebook met dashboards voor de Global salesmanager en product portfolio manager persona's. Al zij het in minder complexe vorm dan in PowerBI.
- Vastlegging en onderbouwing van het proces in de vorm van dit document en de toelichtingen in de notebooks door middel van markdown en comments.

Reflectie

Ik ben tevreden over de uitvoering van de opdracht. Waarschijnlijk ben ik iets te ver doorgeslagen in mijn data-analyse om te kijken wat er was blijven hangen van mijn voorbereidingen. In het modelleren van het PowerBI dashboard en het Python dashboard merkte ik ook dat scope creep snel op de loer ligt bij dit soort projecten. Het doel van het dashboard is niet per se om alle data te presenteren, maar om de specifieke informatiebehoefte te vervullen.

Met betrekking tot het gebruik van AI merk ik dat het, zowel bij theoretische als technische vraagstukken, heel verleidelijk is geworden bij uitdagingen de vraag bij AI weg te leggen en het antwoord te accepteren. Ik merk dat de theorie die ik zelf bestudeerd heb of de stukken code die ik meerdere malen herhaald heb, beter blijven hangen en meer eigen zijn dan de door AI gegenereerde antwoorden.

Transfer

In het vervolg wil ik aandacht besteden aan het vooraf vaststellen van een duidelijkere vastlegging van de scope van het project. Op het moment heb ik deze grens zelf steeds verder verlegd. Het resulterende extra werk staat hierbij niet altijd tegenover de extra moeite die hierin gestoken is.

Met betrekking tot AI wil ik me er bewust van blijven dat deze enkel als aanvulling dient en niet als eindoplossing. Ik scherp mijn huidige werkwijze verder aan, waarbij ik minimaal 1 externe bron kies om te bestuderen en deze aanvul met gerichte vragen aan AI die deze onderbouwd met worked examples en gerichte oefeningscasussen.

8. Bronnen

Databricks. (2026, September 30). *What is Parquet?* Opgehaald van Databricks: https://www.databricks.com/blog/what-is-parquet

Kimball Group. (2026, September 29). *Calendar Date Dimensions*. Opgehaald van Kimball Group: https://www.kimballgroup.com/data-warehouse-business-intelligence-resources/kimball-techniques/dimensional-modeling-techniques/calendar-date-dimension/

McKinney, W. (2022). *Python for Data Analysis.* California: O'Reilly Media, Inc.

ter Braake, P. (2022). *Leerboek Business Intelligence.* Amsterdam: ter Braake & Boom uitgevers.

World Bank Group. (2026, September 30). *GDP per capita.* Opgehaald van World Bank Group: https://api.worldbank.org/v2/en/indicator/NY.GDP.PCAP.CD?downloadformat=csv

9. Tabellenlijst

Tabel 1 Dataprofiel van de opgeschoonde data. 10
Tabel 2 Dimensieverantwoording van de Contoso salesdata met de verschillende dimensies. 12
Tabel 3 Userstories op basis van de verschillende persona's. 18
Tabel 4 Traceability tabel tussen userstories en uitwerking in PowerBI en Python. 19

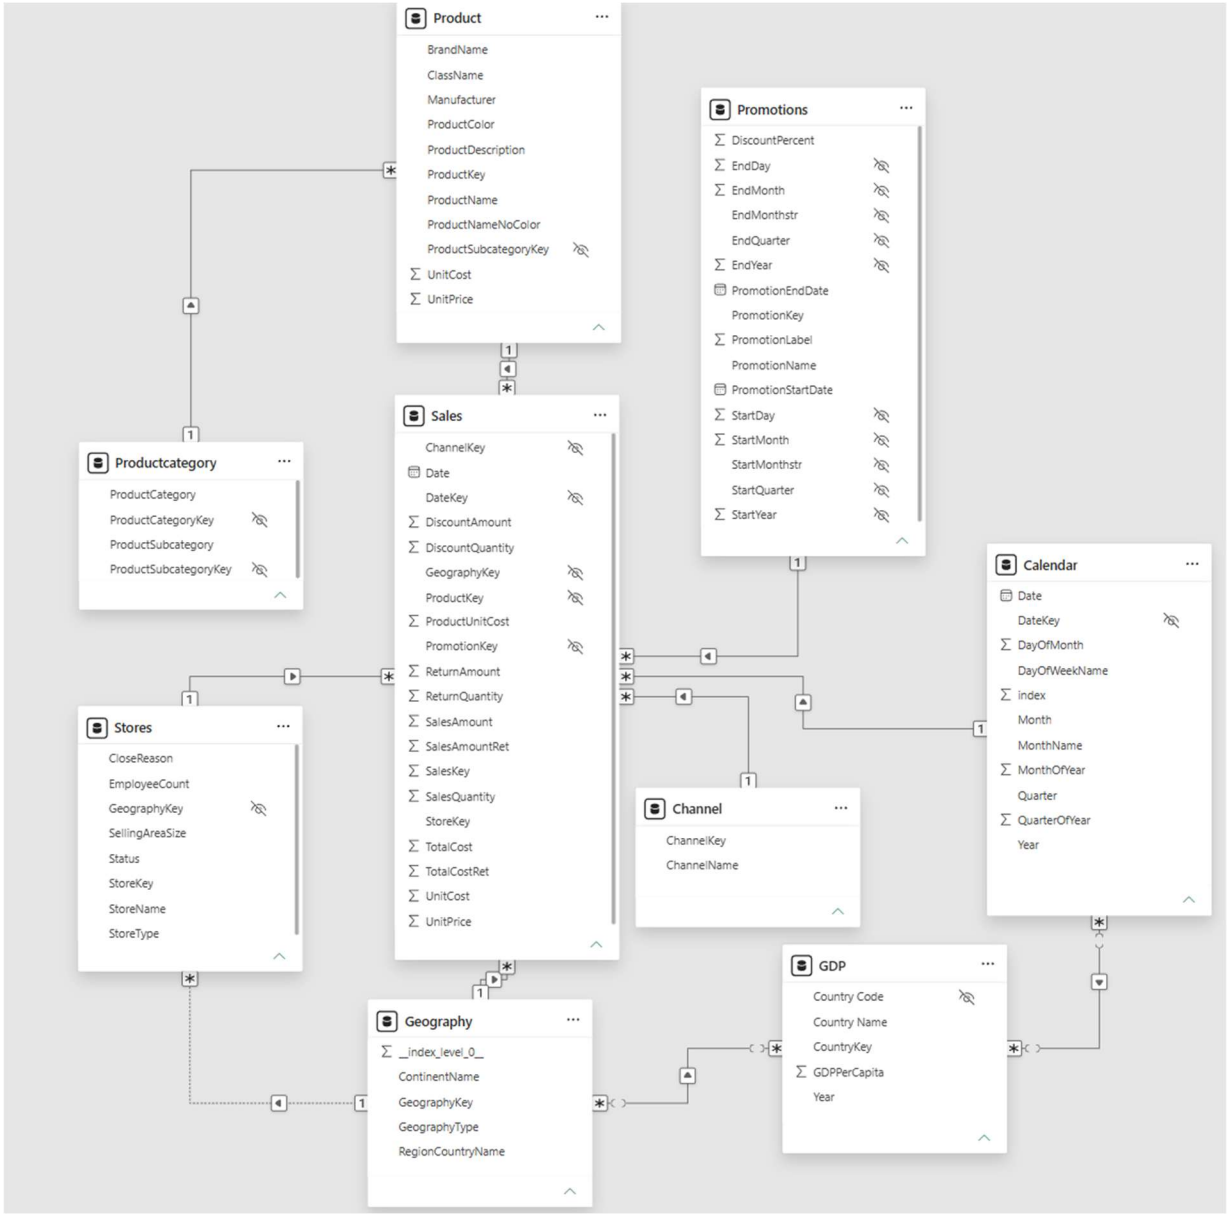
10. Figurenlijst

Figuur 1 Architectuur en gegevensstroom: brondata, parquet als opslag laag en twee rapportagelagen. 11
Figuur 3 Dimensioneel model 14
Figuur 4 Semantisch model 15
Figuur 5 Mock up salesdashboard. 21
Figuur 6 Mockup product portfolio dashboard. 23
Figuur 6 De 4 KPI-kaarten die inzicht geven in de omzet, kosten, brutomarge en brutomarge uitgedrukt in percentage. De waarden betreffen die van het laatste jaar uit de selectie (2013) en vergelijkt deze met het voorgaande jaar (2012). 24
Figuur 8 Revenue by Month is een lijngrafiek die de omzet per maand weergeeft. Eén of meerdere jaren kunnen vergeleken worden met behulp van deze grafiek. De knoppen kunnen gebruikt worden om te wisselen tussen Revenue, Gross Margin en Cost. Andere grafieken reageren ook op deze knoppen. 24
Figuur 9 Revenue by channel is een barchart die omzet, kosten en brutomarge per verkoopkanaal kan vergelijken. 25
Figuur 10 Revenue contribution by product category laat de omzetverdeling per productcategorie zien. Door productcategorieën te selecteren worden de andere grafieken gefilterd en kunnen ontwikkelen op product categorieniveau geanalyseerd worden. 25
Figuur 11 GDP per capita versus revenue Azië 26
Figuur 12 GDP per capita versus revenue Europa. 26
Figuur 13 GDP per capita versus revenue Noord-Amerika. 26
Figuur 14 Het salesdashboard gefilterd op continent Azië. 27
Figuur 14 De 4 KPI-kaarten die inzicht geven in de omzet, aantal verkopen, brutomarge en brutomarge uitgedrukt in percentage. De waarden betreffen die van het laatste jaar uit de selectie (2013) en vergelijkt deze met het voorgaande jaar (2012). 28
Figuur 16 Treechart met omzet per productcategorie voor het jaar 2012. 28
Figuur 16 Treechart met omzet per productcategorie voor het jaar 2013. 28
Figuur 18 Revenue change vs previous year in % laat met behulp van gekleurde balken snel zien welke productcategorieën omzetstijgingen en dalingen vertonen. De absolute bedrage worden in miljoenen vermeld. 29
Figuur 19 Een drilldown in de categorie "cameras and camcorders" laat zien dat cameras and camcorders ten opzichte van het vorige jaar aanzienlijk minder omzet opleveren. 29
Figuur 20 Lijst van top 10 producten 30
Figuur 21 Piechart die het aandeel in de kosten van iedere fabrikant/leverancier voor Contoso laat zien. 30
Figuur 22 Gross margin versus sales quantity met een drilldown op de productcategorie computers. 31
Figuur 23 Gross margin versus sales quantity laat de relatie tussen afzet, brutomarge en omzet zien op productcategorieniveau. 31
Figuur 23 Het productportfolio dashboard gefilterd op productcategorie computers. 32
Figuur 24 Dimensioneel model met geïmporteerde data in PowerBI. 37

11. Bijlagen

Bijlage A. Dimensioneel model in PowerBI

In Figuur 24 is het dimensioneel model terug te zien zoals dit in PowerBI is geïmporteerd.



Figuur 24 Dimensioneel model met geïmporteerde data in PowerBI.